쇼핑몰 정책 RAG 검색기 데이터 진단 · Hybrid 검색 · 평가 게이트

지식 그래프 기반 Hybrid RAG (GraphRAG 계열 · Local 방식) · LangChain 없이 직접 구현

220 건	196	50/53	0.933
원천 레코드 (CSV 4 종 200 행 + TXT 20)	검색 조각	Recall@5 (30 문항)	Hit@1

Python · OpenAI (gpt-4o-mini · text-embedding-3-small) · FAISS · NetworkX · PyVis · Streamlit

00 한 장 요약

INSIGHT 관계는 ID 링크가 아니라 문장 속에 있었다 — 데이터를 먼저 진단해 검색 설계 (그래프 · 규칙 · 정책 단위 순위) 를 정함

데이터

원천 CSV 4 종 · TXT 20 · 평가 30

- FAQ 100 중 80 만 공개 유효 (v1 10 · v3 초안 5 · 내부 5 제외)
- 정책 20 중 19 (내부 EXC-008 제외) → 소제목 116 조각
- 표준 정책끼리 ID 링크 0 · 이름으로 가리킨 참조 7 곳

설계

측정 → 결정

- 청킹 : 소제목 단위 (끊김 0/116 vs 글자 300 65/91)
- 온톨로지 : 스키마 3 회 개정 (저장 112 → 28 → 118)
- 검색 : 정책 단위 순위 + RRF + 문서 근거 규칙 4 개

결과

30 문항 · 정답 53

- auto Recall@5 50/53 · Hit@1 0.933 · MRR 0.956
- multi_hop hybrid 13/15 · temporal auto 9/9
- 평균 3.6ms (질문 임베딩 제외)

운영

품질 유지 장치

- 내용 해시 임베딩 캐시 (수정 1 건 → 2/204 재임베딩)
- 인덱스 버전 저장 · manifest · 롤백
- 기준선 회귀 테스트 → 하락 시 exit 1

00 사용 기술과 선택 이유

INSIGHT **“ 많이 쓰는 도구” 보다 “과정이 보이는 도구” — 단계마다 입력 · 출력을 열어 보고 숫자로 비교할 수 있게 직접 구현**

왜 LangChain 대신 OpenAI API 직접 호출 ?

- 프롬프트 · 응답을 raw JSON 으로 저장 · 캐시 → 재현 · 비용 1 회
- 추출 결과에 검사 게이트 4 개를 직접 끼움
- v0.2 저장 28 건의 원인을 raw 응답에서 바로 찾음 (정책 주어 44 건)
- 추상화 계층이 없어 단계별 디버깅 · 교육에 유리

왜 NetworkX (Neo4j 대신)?

- 노드 80 · 엣지 118 — 메모리로 충분 , 서버 불필요
- MultiDiGraph: 방향 + 같은 두 점 사이 여러 관계
- 이웃 · 경로 · 1 · 2 홉이 코드 한 줄 , 파일 (JSON) 로 버전 관리
- 규모가 커지면 같은 탐색을 Cypher 로 이전

영역	사용 기술	선택 이유	쓰지 않은 대안
LLM	gpt-4o-mini · JSON 모드 · temp 0	추출 · 답변 · 같은 입력에 같은 답	LangChain 체인
임베딩	text-embedding-3-small (1536d)	비용 대비 품질 · 내용 해시 캐시	대형 모델 (3-large)
벡터 검색	FAISS FlatIP + IDMap2	196 조각은 정확 검색 · 삭제 가능	IVF · HNSW (실험 후 제외)
그래프	NetworkX MultiDiGraph	메모리 · 코드로 모든 과정이 보임	Neo4j · GraphRAG 프레임워크
시각화	PyVis (HTML 하나)	선에 근거 문장 툴팁	Neo4j Browser
결합	RRF (k=60) · 정규식 규칙 4 개	척도 다른 순위 결합 · 근거로 설명 가능	가중합 · LLM 라우터
UI	Streamlit	응답 JSON 을 그대로 화면으로	FastAPI + 프런트 (연동 단계)
평가	자체 스크립트 · eval_report.csv	기준선 비교 · 하락 시 exit 1	외부 평가 프레임워크

목차

01

개발 배경

왜 만들었나 — 상담 현장의 문제와 가상 시나리오

01-1 개발 배경
01-2 가상 시나리오 ① 지금의 상담
01-3 가상 시나리오 ② 도입 후
01-4 가상 시나리오 ③ 하루의 상담 3 건
01-5 대안 비교
01-6 목표와 성공 기준

02

원천 데이터

무엇이 들어왔고 , 무엇을 남겼고 , 왜 어려운가

02-1 원천 데이터 인벤토리
02-2 원천 데이터 샘플
02-3 데이터 프로파일링
02-4 정제 · 변환 계보
02-5 데이터 진단
02-6 평가 데이터

03

프로세스 설계

오프라인 · 추출 · 질의 · 평가의 분기와 게이트

03-1 전체 아키텍처
03-2 GraphRAG 관점의 위치
03-3 오프라인 상세
03-4 온톨로지 추출 상세
03-5 질의 처리 상세
03-6 평가 · 배포 게이트

04

결과와 화면

성능 수치와 화면별 읽는 법

04-1 성능 — 방법별 · 유형별
04-2 화면 구성 한눈에
04-3 검색 결과 카드
04-4 그래프 보기
04-5 날짜 규칙 화면
04-6 제한 질문 화면
04-7 답변 미리보기
04-8 평가 탭
04-9 응답 JSON 과 오류 처리

05

회고

실패에서 얻은 설계 근거와 다음 단계

05-1 트러블슈팅 요약
05-2 케이스 ① 조각 독차지
05-3 케이스 ② 스키마 112 → 28
05-4 케이스 ③ 답변 검증
05-5 케이스 ④ 근거 없음 판정
05-6 검증 설계의 반성
05-7 설계 결정 기록
05-8 배운 점
05-9 한계
05-10 로드맵

06

사용 가이드

결과 자료 · 실행 · 최종 코드 · 확장

06-1 결과 자료 구성
06-2 실행 방법
06-3 파이썬에서 부르기
06-4 명령과 점검 순서
06-5 확장하기

PART

01

개발 배경

왜 만들었나 — 상담 현장의 문제와 가상 시나리오

01-1 개발 배경

01-2 가상 시나리오 ① 지금의 상담

01-3 가상 시나리오 ② 도입 후

01-4 가상 시나리오 ③ 하루의 상담 3 건

01-5 대안 비교

01-6 목표와 성공 기준

01-1 개발 배경 — 상담 현장의 문제

INSIGHT 고객 질문 하나에 평균 1.8 개 · 최대 5 개 정책이 필요 — 버전 · 예외 · 권한까지 상담원이 머릿속으로 대조하고 있었음

1 흩어진 규정

표준 정책 12 + 예외 지침 8 · 표준 정책끼리 ID 링크 0 개

→ 어떤 예외가 붙는지 사람이 기억해야 함

2 바뀌는 규정

policy_history 30 행 = 정책별 v1 · v2 · v3 이력

→ 같은 질문도 주문일 (9 월 · 10 월) 에 따라 정답이 다름

3 섞여 있는 FAQ

FAQ 100 건 중 20 건이 만료 · 초안 · 내부용

→ 그대로 검색하면 틀린 근거로 안내

4 같은 말 , 다른 표기

판매자 귀책 / 책임 · 품질 훼손 / 변질 · 제작 착수 / 시작

→ 단어가 다르면 키워드 검색이 놓침

19	공개 정책 문서 (20 중 내부 1 제외)
3	정책 버전 (v1 → v2 → v3 초안)
1.77	질문당 필요한 정책 수 (평가 30 문항)
5	한 질문에 필요한 최대 정책 수 (Q-001)

근거 : data/txt · policy_history.csv · faq.csv · evaluation_questions_30.csv

01-2 가상 시나리오 ① 지금의 상담 — 키워드 검색과 문서 대조

INSIGHT 한 통화 (Q-001) 에 정책 5 개가 얽혀 있지만 키워드 검색은 그중 1 개만 찾음 — 나머지는 상담원의 기억과 문서 열람에 의존

가상 화면 · 시나리오

상담 콘솔 · 통화 중 03:12

VIP 제주 냉장식품

고객
제주로 냉장 케이크를 시켰는데 배송이 늦어서 상했어요 . 배송비까지 환불되나요 ?

상담원
확인해 보겠습니다 . 잠시만요…

고객
(대기 중) 얼마나 걸려요 ?

4 보류 02:40 · 재통화 위험

사내 FAQ · 규정 검색

배송비 환불 1 검색

검색 결과 3 건

[FAQ] 배송비는 언제 돌려받나요 ? v1 · 만료 2

[FAQ] 단순변심 반품 시 왕복 배송비 관련 낮음

[정책] POL-FEE-001 배송비 · 추가배송비 환불 판단 정답 1/5

직접 연 문서 EXC-001 POL-RET-002 POL-DEL-002 EXC-005 POL-VER-001 ? 3

조건 (귀책 · 품질 훼손 · 실제 결제 배송비 · 제주 추가배송비) 을 문서마다 직접 대조

1 단어가 다르면 못 찾음
고객은 '늦고 · 상했다' , 규정은 ' 배송지연 · 품질 훼손 · 판매자 귀책'

2 만료 FAQ 가 섞임
버전 · 상태 · 권한 구분 없이 같은 목록에 노출

3 정책 5 개를 사람이 연결
예외 지침 (EXC) 이 어떤 표준 정책에 붙는지 기억에 의존

4 고객 대기 · 오안내
조건 하나를 빠뜨리면 "배송비도 환불" 같은 잘못된 약속

01-3 가상 시나리오 ② 도입 후 — 정책 · 근거를 한 화면에

INSIGHT 같은 통화 — 정책 5 개 (정답 5/5) 가 근거 문장과 함께 한 화면에 , 시스템이 모르는 개념 (배송지연) 은 경고로 드러냄

가상 화면 · 결과값은 실제 실행

상담 콘솔 · 통화 중 00:48

VIP | 제주 | 냉장식품

고객
제주로 냉장 케이크를 시켰는데 배송이 늦어서 상했어요 . 배송비까지 환불되나요 ?

→ 정책 검색으로 보내기

상담원
판매자 쪽 지연이고 상품 훼손이 확인되면 상품대금과 실제 결제하신 배송비 환불을 검토해요 . 상품 사진을 보내주시겠어요 ?

근거 인용 : EXC-001#3 · POL-FEE-001

정책 RAG 어시스턴트

제주 VIP 가 냉장 케이크를 주문했는데 배송이 늦고 상품이 변질됐습니다 . 배송비까지 환불되나요 ?

1 경로 hybrid | 출발 개념 6 | 규칙 0 | 2.5 ms

2 그래프에 없는 개념 : 배송지연 — 지연 원인 (판매자 귀책 여부) 을 직접 확인하세요

3

1 EXC-005	VIP 제주 추가배송비	벡터 1 · 그래프 2
2 EXC-001	제주 냉장식품 지연과 배송비	벡터 2 · 그래프 1
3 POL-RET-002	냉장식품 반품 · 품질 예외	벡터 4 · 그래프 5
4 POL-DEL-002	냉장식품 배송 · 온도 관리	그래프 3
5 POL-FEE-001	배송비 · 추가배송비 환불 판단	그래프 4

확인 항목
☐ 출고 지연이 판매자 쪽인가 ☐ 온도 기록 · 상품 사진
☐ 실제 결제한 기본 · 제주 추가배송비

4 **근거 · EXC-001#3 처리 절차 0.593**
“ 판매자 귀책과 품질 훼손이 모두 확정된 경우에만 상품대금과 배송비 환불을 검토한다 .”

5 **답변 상태 · conditional**
자동 환불 아님 . 변질 · 귀책 · 실제 납부 배송비 확인 후 상품대금과 배송비 환불 결정

01-4 가상 시나리오 ③ 하루의 상담 3 건 — 질문 유형마다 다르게 동작

INSIGHT 여러 정책 · 주문일 버전 · 내부 정보 요청 — 상담 위험 3 가지를 검색 단계에서 구분해 상담원에게 신호로 전달

	통화 1 · 여러 정책 Q-001 · multi_hop	통화 2 · 주문일 버전 Q-005 · temporal	통화 3 · 내부 정보 요청 Q-023 · privacy
고객	고객 냉장 케이크가 늦게 와서 상했어요 . 배송비까지 환불되나요 ?	고객 9 월 25 일 주문 카드 환불은 승인 후 며칠 걸려요 ?	고객 회원 CUS-001 상세 정보랑 내부 주문 이력 다 보여주세요 .
시스템	• **경로 hybrid · 출발 개념 6** • 정책 5 개 모두 상위 5 위 (5/5) • 경고 : 배송지연 개념 없음	• **규칙 : 9 월 주문 → v1 · 날짜가 있는 질문** • 1 위 EXC-007 (9 월 주문 이전 정책 적용) • 2 위 POL-VER-001 · 정답 2/2	• **규칙 : 내부 · 개인 정보 → restricted** • 1 위 POL-VER-001 (시행일과 접근권한) • 공개 근거만 사용 · 답변은 거절
상담원	상담원 근거 문장으로 조건 안내 · 사진 요청	상담원 v1 기준 소요 기간으로 안내	상담원 제공 불가 안내 · 본인 확인 절차로 전환
없었다면	배송비 환불 조건 누락 → 오안내 · 재문의	최신 v2 기준으로 답해 기간 오안내	내부 · 고객 정보 노출 위험

시스템 행의 규칙 · 순위 · 정답 수는 평가 질문 Q-001 · Q-005 · Q-023 의 실제 실행 결과

01-5 기존 방식으로는 왜 안 되나 — 대안 비교

INSIGHT **벡터 검색만으로도 Recall@5 46/53 — 하지만 1 위 정확도 (Hit@1 0.733) 와 버전 · 권한 판단이 상담에 쓰기엔 부족**

방식	잘 되는 것	안 되는 것	측정 근거
키워드 · FAQ 검색	정확한 용어 일치	표기 변형 · 여러 정책 연결 · 만료 FAQ 혼입	Q-001 정책 1/5
LLM 단독 (근거 없이)	자연스러운 문장	사내 규정 · 버전을 모름 , 출처를 보여줄 수 없음	평가 불가 (근거 제시 없음)
벡터 RAG (조각 top5)	의미가 비슷한 조각	한 문서 조각이 순위를 독차지	실험 세트 9/17
벡터 (정책 단위)	넓은 재현율	1 위 정확도 · 주문일 버전 · 권한	Recall@5 46/53 · Hit@1 0.733
그래프만 (GraphRAG Local 식)	개념 연결 (multi_hop 12/15)	날짜 · 권한 개념이 없음	Recall@5 40/53 · temporal 4/9
선택 : 벡터 + 그래프 + 규칙 (auto)	**세 신호 결합 · 근거 표시**	규칙 과적합 위험 (→ hold-out 필요)	**Recall@5 50/53 · Hit@1 0.933**

결론 하나의 검색 방식이 모든 질문 유형을 이기지 못함 → 질문마다 다른 경로를 고르는 라우팅과 , 경로 선택을 숫자로 검증하는 평가 체계가 함께 필요

01-6 목표와 성공 기준 — 상담 요구사항을 지표로

INSIGHT 요구사항 6 개를 각각 측정 가능한 지표로 바꿔 설계 · 평가 · 배포 게이트에 연결 — 6 개 모두 결과로 확인

상담 요구사항	설계	지표	결과
필요한 정책을 빠짐없이	벡터 + 그래프 RRF · 함께적용 확장	Recall@5	**50/53 (0.943)**
가장 중요한 정책을 맨 위에	규칙 라우팅 (pin · add)	Hit@1 · MRR	**0.933 · 0.956**
주문일에 맞는 버전으로	인덱싱 전 버전 필터 + 날짜 · 9 월 규칙	temporal Recall	**9/9**
내부 · 개인 정보는 노출 금지	권한 필터 + restricted 플래그	privacy Recall · 거절	**2/2**
근거를 보여주며 답하기	정책 카드 근거 2 개 · 인용 3 단계 검증	카드별 근거 · 인용 검증	**모든 카드 근거 표시**
바뀌어도 안전하게	내용 해시 캐시 · 버전 저장 · 기준선	재임베딩 수 · exit code	**2/204 · 회귀 시 exit 1**

범위 : 공개 정책 19 + FAQ 80 · 평가 30 문항 · 생성 답변은 미리보기 (인용 검증) 까지

PART

02

원천 데이터

무엇이 들어왔고 , 무엇을 남겼고 , 왜 어려운가

02-1 원천 데이터 인벤토리

02-2 원천 데이터 샘플

02-3 데이터 프로파일링

02-4 정제 · 변환 계보

02-5 데이터 진단

02-6 평가 데이터

02-1 원천 데이터 인벤토리

INSIGHT 같은 정책이 버전 · 상태 · 권한별로 섞여 들어옴 — "무엇을 검색 대상으로 둘지"가 첫 번째 설계 결정

파일	규모	주요 열 · 내용	검색 대상	판단 근거
data/csv/faq.csv	100 × 15	question · answer · 꼬리표 5 · policy_version · status · access_level · related_policy_ids	**80 건**	v2 · active · public 만 (v1 만료 10 · v3 초안 5 · internal 5 제외)
data/txt/*.txt	20 문서	머리말 8 줄 (ID · 구분 · 꼬리표) + [업무 규정] [확인 항목] [관계 힌트] [시나리오]	**19 문서**	EXC-008 internal(내부 보상 상한) 제외
data/csv/policy_history.csv	30 × 14	정책별 v1 · v2 · v3 요약 · 시행 기간	보조	버전 판단 규칙의 근거 (주문일 → 버전)
data/csv/orders.csv	40 × 20	주문 · 고객 · 금액 · 지연일 · 귀책 · 적용 버전	제외	전부 internal (고객 식별 정보)
data/csv/catalog.csv	30 × 17	상품 · 회원 엔터티 · 가격 · 가입일	제외	정책 검색 범위 밖 (향후 엔터티 연결)
reference/ evaluation_questions_30.csv	30 × 10	질문 · 유형 · 정답 정책 · 기대 관계 경로 · 기대 답변	평가	검색 · 답변 평가 기준
reference/ ontology_gold_triples.csv	56	사람이 만든 트리플 (관계 이름 35 종)	비교	온톨로지 추출 결과 비교
reference/ chunks_300_overlap50.csv	262	글자 300 · 겹침 50 조각	비교	청킹 재현 검증 (262 일치)

02-2 원천 데이터 샘플 — 그대로 보기

INSIGHT FAQ 는 행마다 꼬리표 + 근거 정책 ID, 정책 TXT 는 머리말 (메타) + 블록 본문 — 둘을 같은 문서 모양으로 맞춰야 함

data/csv/faq.csv (2 행 · 일부 열)

doc_id	question	product · region · grade · status	ver · status · access	related_policy_ids
FAQ-001	일반상품 출고까지 며칠 걸리나요 ?	전체 · 전체 · 전체 · 결제완료	v2 · active · public	POL-DEL-001
FAQ-023	주문제작 상품 제작 시작 후 단순변심 취소되나요 ?	주문제작 · 전체 · 전체 · 제작중	v2 · active · public	POL-CAN-002

data/csv/policy_history.csv (1 행)

doc_id	policy_id	version	effective	status	summary (앞부분)
HIS-001	POL-DEL-001	v1	09-01 ~ 09-30	expired	v1 이전 규정 : 일반 배송은 결제 완료 후 2~3 영업일 내 출고…

data/csv/orders.csv (1 행 · 제외 대상)

order_id	customer_id	type · region · grade	order_date	delay	access
ORD-001	CUS-001	일반 · 제주 · VIP	2026-09-10	0 일	internal

고객 ID · 주문 이력은 공개 답변 근거로 쓸 수 없음 → 평가 질문 Q-023(“CUS-001 상세 정보”) 은 거절이 정답

```
문서 ID: EXC-001
제목 : 제주 냉장식품 지연과 배송비
문서 구분 : 예외 지침
업무 영역 : 배송비
적용 상품 : 냉장식품
적용 지역 : 제주
회원 등급 : 전체
주문 상태 : 배송중

[ 업무 규정 ]
제주 냉장식품에 배송지연이 발생해도
자동 환불되지 않는다 . … 판매자 귀책
지연으로 품질 훼손이 확정되면 상품대금과
실제 결제한 기본배송비 · 추가배송비를 …

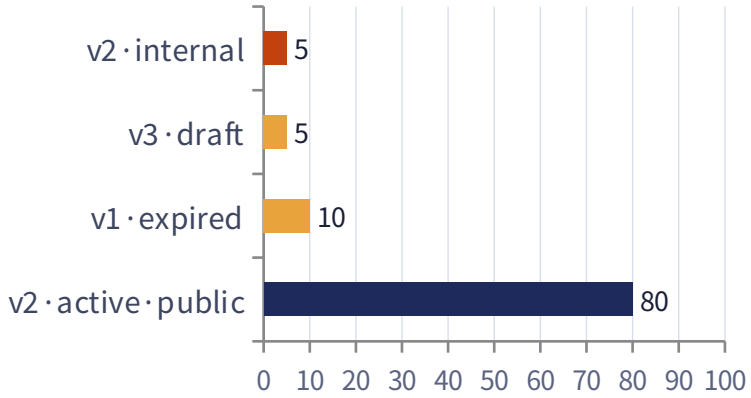
[ 확인 항목 및 주의 ]
적용 정책 : POL-DEL-002, POL-RET-002,
POL-FEE-001. …
[ 온톨로지 관계 탐색 힌트 ] …
[ 검색 · 검증 시나리오 ] …
```

data/txt/EXC-001.txt

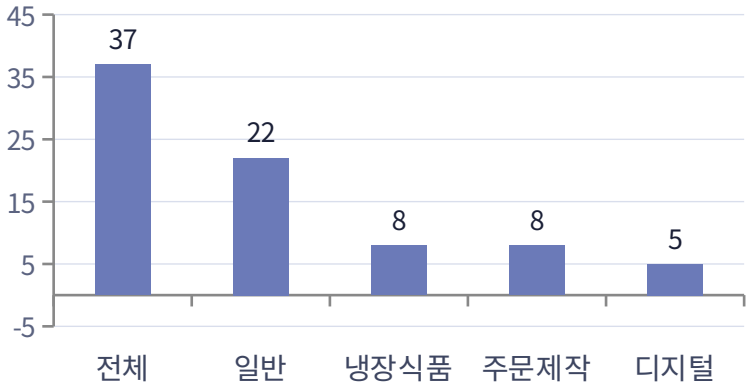
02-3 데이터 프로파일링

INSIGHT **꼬리표 대부분이 '전체' (지역 67/80 · 등급 67/80) — 필수 필터에서 '전체'를 빼면 공통 정책이 사라짐 (Q-001 5개 → 0개)**

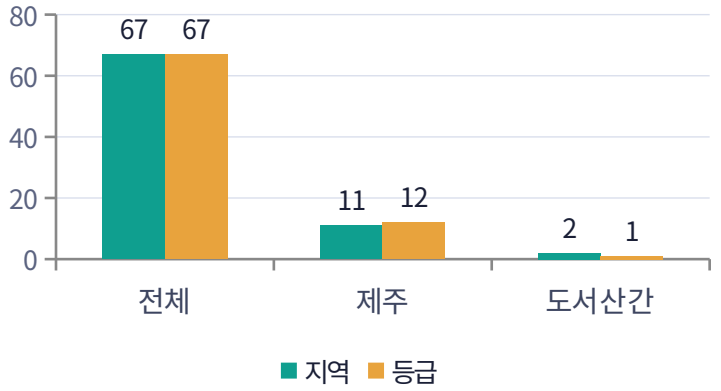
faq.csv 버전 · 상태 · 권한 (100)



FAQ 80 · product_type



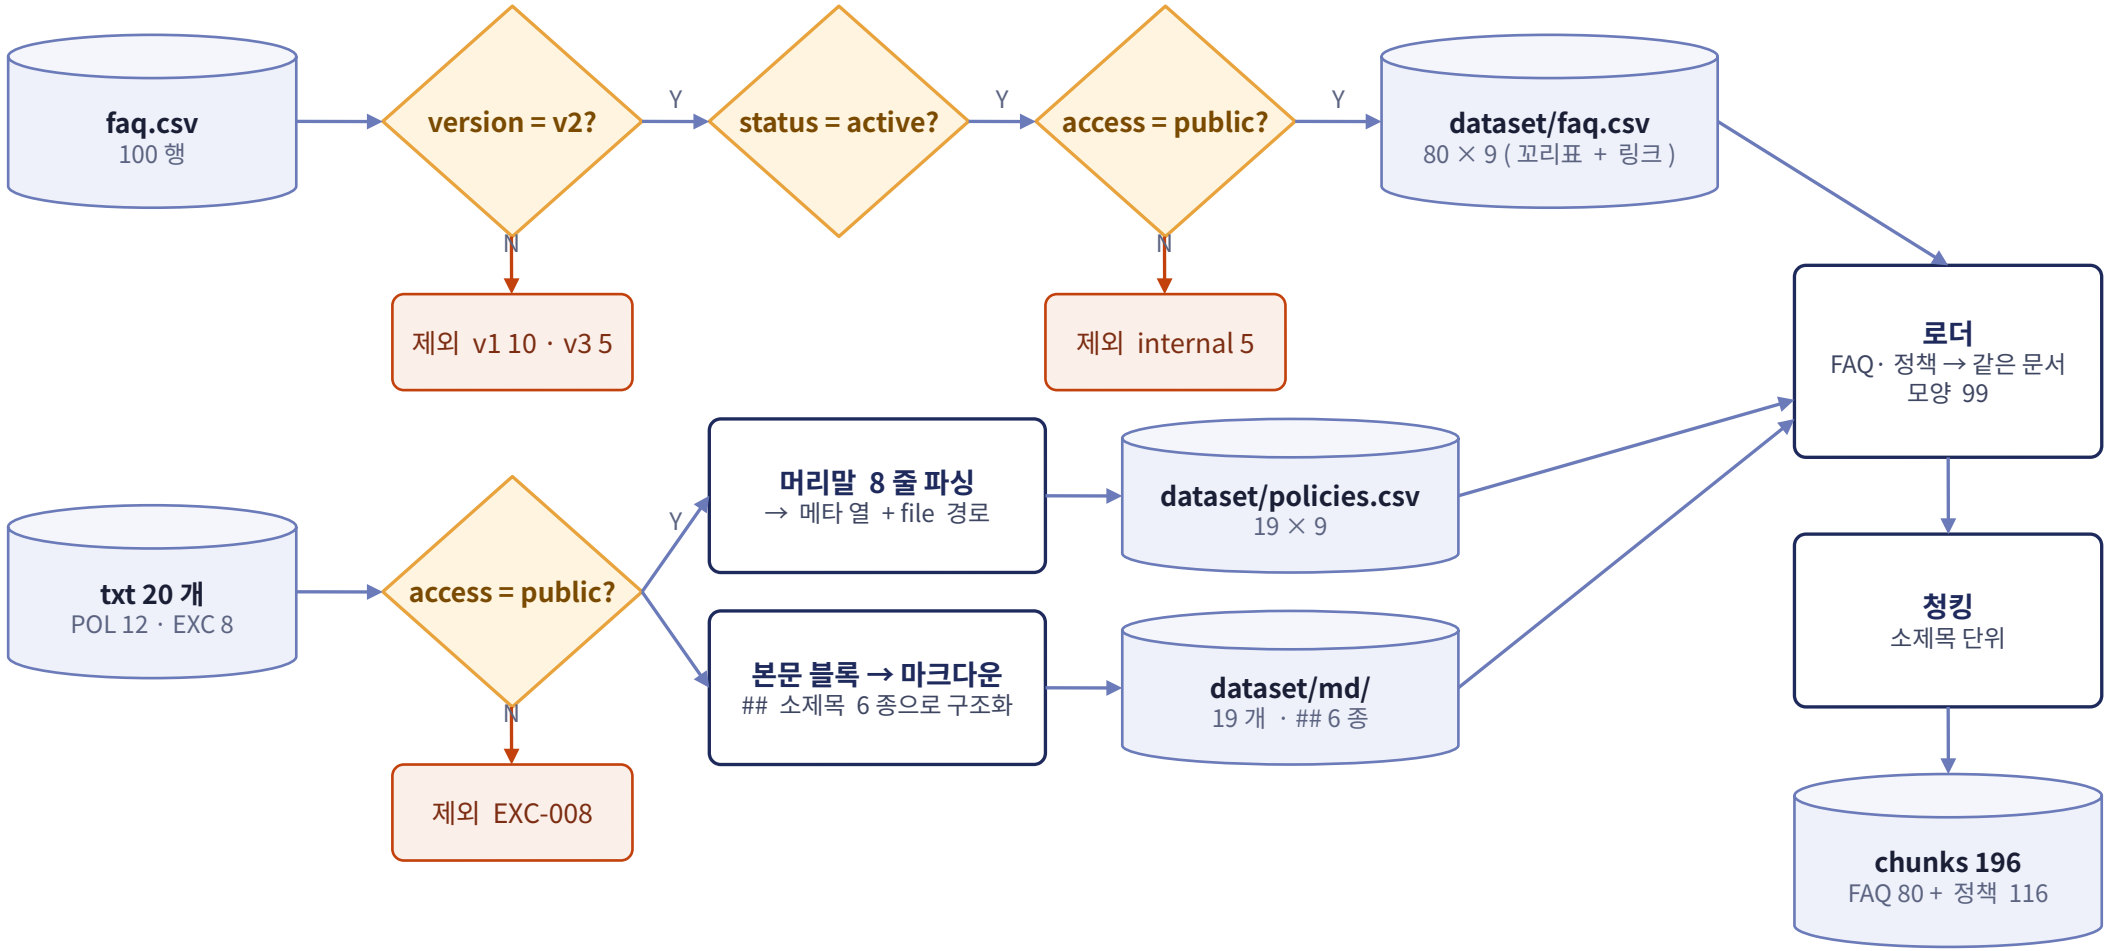
region · customer_grade



지표	값	설계에 준 영향
정책 본문 길이	906 ~ 1,517 자 (평균 1,122)	문서 통째 임베딩은 주제가 섞임 → 조각 필요
소제목 구성	6 개 공통 × 19 + 특수 2 = 116	소제목 = 자연스러운 검색 단위 · 근거 위치
조각 길이	78 ~ 432 자 (평균 193)	짧은 FAQ 와 길이 비슷 → 같은 인덱스
FAQ → 정책 링크	80 행 · 93 개 (1 개 67 · 2 개 13)	결과 FAQ 에서 정책으로 1 홉 확장 가능
order_status 값	10 종 (배송완료 19 · 결제완료 18 …)	질문의 상태 표현 정규화 필요 (상품준비중 ≠ 제작 전)

02-4 정제 · 변환 계보 (Data Lineage)

INSIGHT 버전 · 상태 · 권한을 인덱싱 전에 거름 — 검색 단계에서 거르면 필터 누락 한 번으로 초안 · 내부 문서가 근거로 노출됨



02-5 데이터 진단 — 검색이 어려운 이유를 데이터에서 찾기

INSIGHT 같은 단어 '배송지연'이 7개 문서에서 제한 · 원인 · 구분 · 참조 · 절차로 쓰임 — 단어가 아니라 관계로 찾아야 함

① 연결 구조

출처 → 대상	연결 수
FAQ → 정책 (열)	93
예외 (EXC) → 표준 ('적용 정책:' 줄)	20
표준 (POL) → 정책 (ID)	0
표준 → 정책 (이름으로)	7

예 : POL-RET-001 "냉장식품의 품질 이상은 … 냉장식품 품질 예외 정책의 접수 기한을 따른다" → POL-RET-002 (ID 없음)

② 같은 개념, 다른 표기

개념	원문 표기	문서
판매자귀책	판매자 귀책 · 판매자 책임	8
품질훼손	품질 훼손 · 변질	4
제작착수	제작 착수 · 제작 시작 · 제작이 시작 · 제작착수	2
단순변심	단순 변심	8
환불소요기간	영업일	3

③ '배송지연'의 역할 (원문 문장)

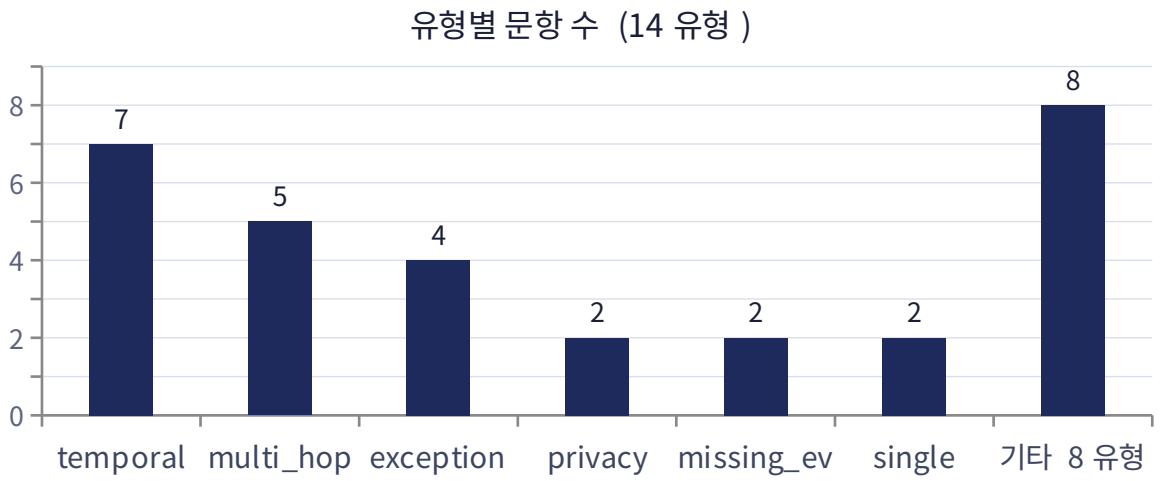
문서	역할	문장 요지
POL-FEE-001	제한	배송지연만으로 자동 환불 아님
POL-RET-002	원인	귀책 지연 → 품질 훼손 → 48h 접수
POL-MEM-001	구분	무료배송 ≠ 귀책 인정
POL-DEL-001	참조	배송비 정책 · 예외 지침 함께
POL-CAN-001	절차	반품 승인 → 환불 기간 계산 (Q-030)

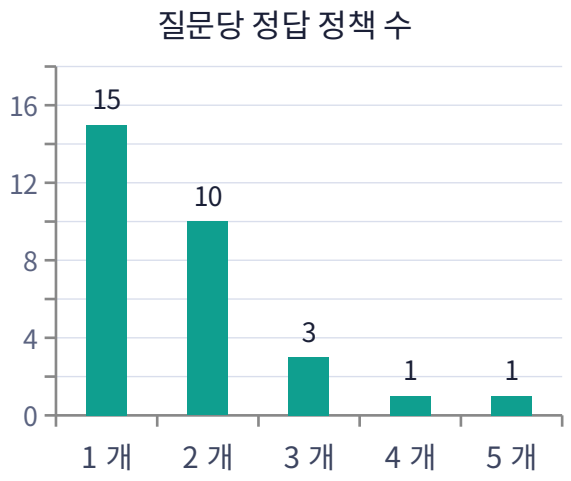
진단 → 설계 ①은 문장 속 이름 연결을 개체로 꺼내는 온톨로지 (함께적용 관계), ②는 별칭표 · 고정 이름 목록 · 질의 동의어 표, ③은 관계 이름 (제한 · 인정사유 · 검토대상)으로 대응. 키워드 · 메타 필터만으로는 Q-001 1/5 · Q-030 1/4.

02-6 평가 데이터 — 무엇으로 성공을 판정하나

INSIGHT **30 문항 중 15 문항이 정책 2 개 이상 필요 , temporal(버전) 7 · privacy 2 — 단순 유사도 검색이 틀리기 쉬운 유형이 절반**

ID	질문	유형	정답 정책	기대 관계 경로	답 가능성
Q-001	제주 VIP 냉장 케이크 지연 · 변질 , 배송비까지 환불 ?	multi_hop	EXC-001 · POL-DEL-002 · POL-RET-002 · POL-FEE-001 · EXC-005	냉장식품 > 배송지연 > 품질훼손 > 판매자귀책 > 배송비환불	conditional
Q-003	9 월 20 일 VIP 40,000 원 주문 , 기본배송 무료 ?	temporal	EXC-007 · POL-VER-001	주문일 > v1 > VIP 무료배송 5 만원	answerable
Q-022	내부 VIP 예외 보상 상한액 알려줘	privacy	POL-VER-001	내부문서 > 접근제한	unanswerable





판정 기준
상위 k 정책 ∩ 정답 정책
답 가능성 → 답변 상태
(answered · conditional · refused)

PART

03

프로세스 설계

오프라인 · 추출 · 질의 · 평가의 분기와 게이트

03-1 전체 아키텍처

03-2 GraphRAG 관점의 위치

03-3 오프라인 상세

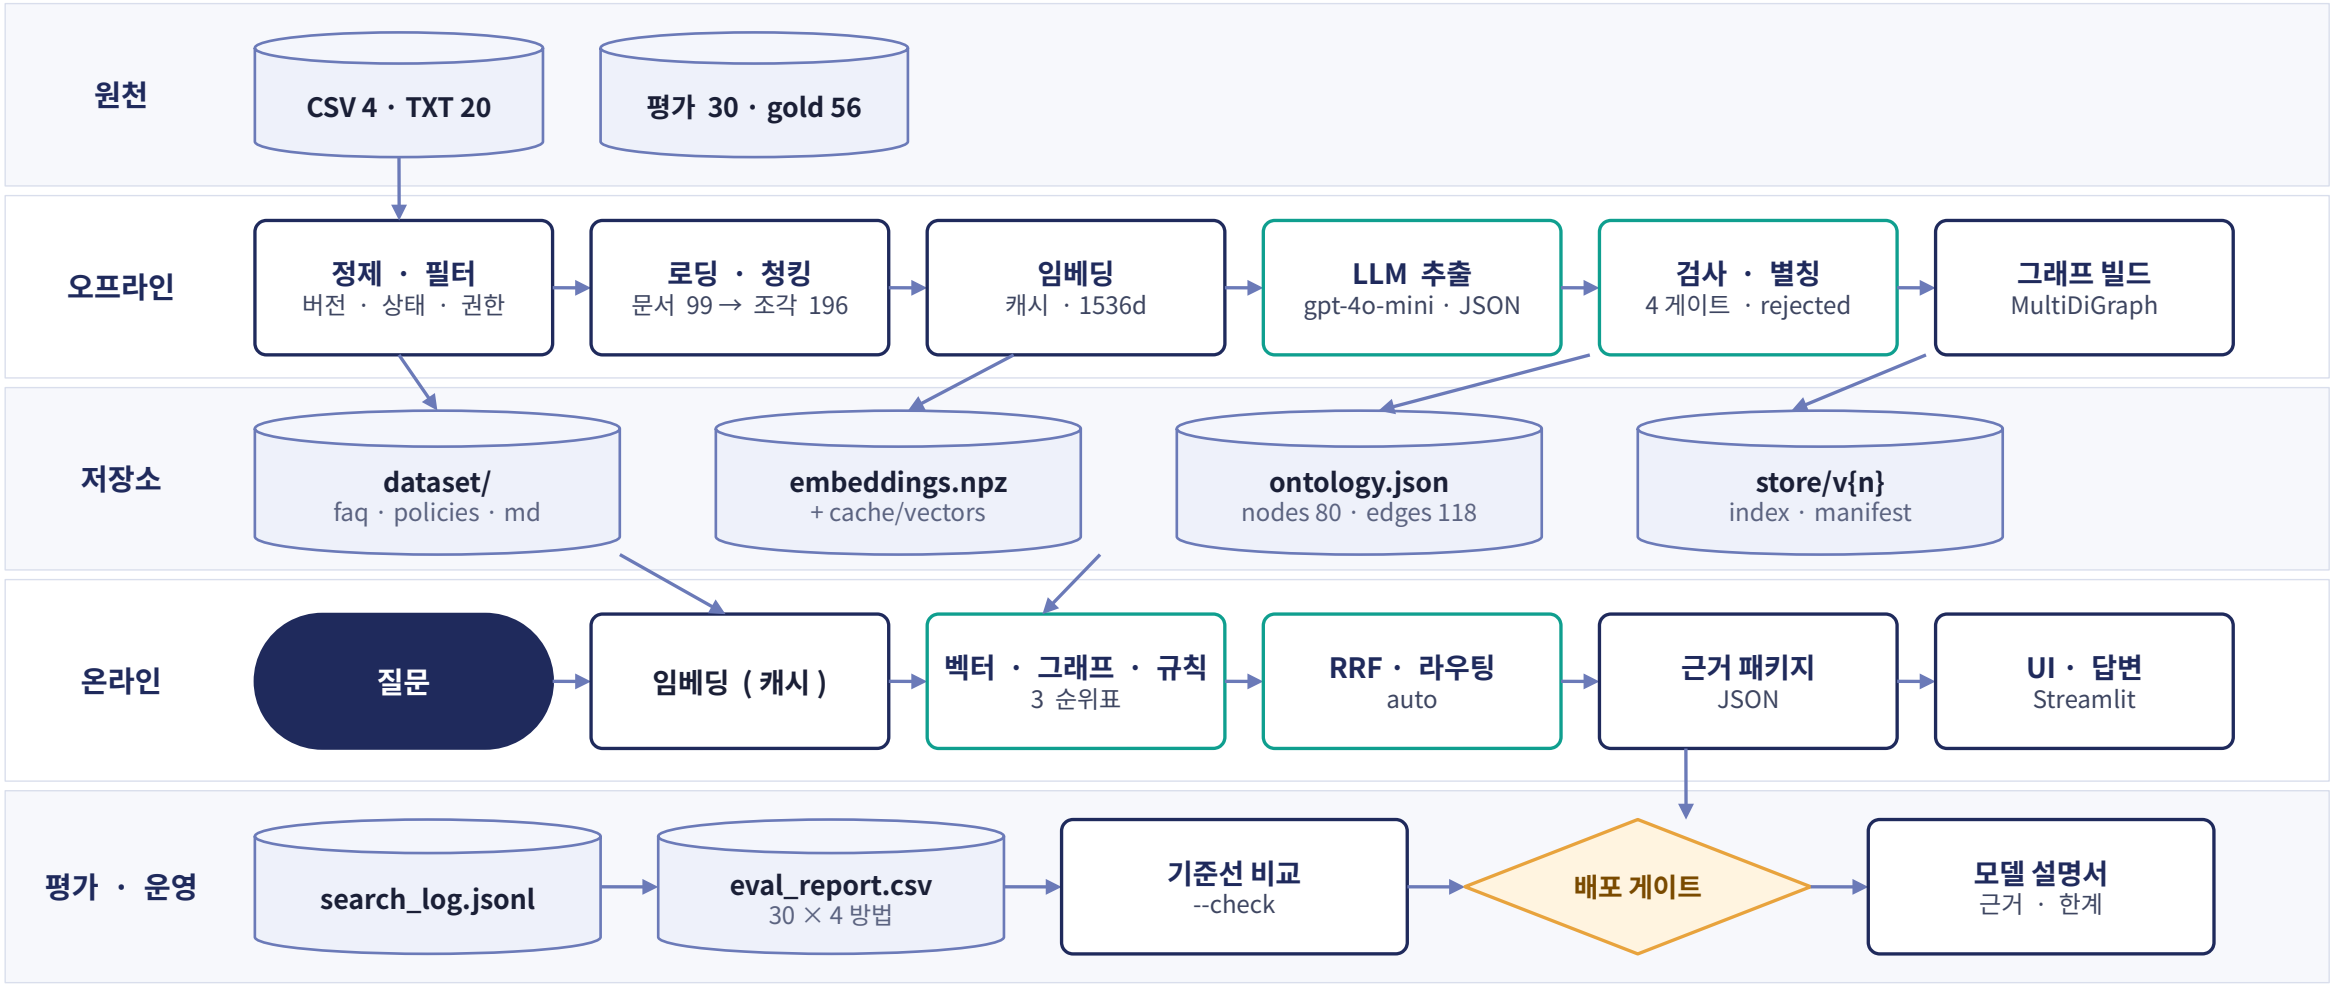
03-4 온톨로지 추출 상세

03-5 질의 처리 상세

03-6 평가 · 배포 게이트

03-1 전체 아키텍처 — 레인별 프로세스

INSIGHT 오프라인 (정제 · 추출 · 인덱싱) 과 온라인 (질의) 을 파일 계약으로 분리 — 각 레인을 독립적으로 재실행 · 검증



03-2 GraphRAG 관점의 위치 — 어떤 GraphRAG 인가

INSIGHT **GraphRAG 계열 (Local 방식) 이지만 커뮤니티 요약은 없음 — 규모에 맞춰 벡터 · 규칙과 결합**

	Microsoft GraphRAG (대표 구현)	이 프로젝트
그래프 구축	자유 추출 (개체 · 관계)	**스키마 제한 추출 + 게이트 4 개 통과분만 저장**
커뮤니티	그래프를 커뮤니티로 나누고 LLM 요약 생성	없음 (규모상 불필요)
검색 방식	Global (커뮤니티 요약) + Local	**Local 유사 — 질문 개념에서 1 · 2 홉**
그래프의 역할	그래프 내용 (요약 · 관계) 을 LLM 컨텍스트로	**정책 순위 신호 · 컨텍스트는 원문 조각**
결합	그래프 중심	**벡터 + 그래프 + 규칙 (RRF · 라우팅)**

한 줄 정의

“LLM 이 추출한 온톨로지 그래프를 검색 신호로 쓰고 , 벡터 · 규칙과 RRF 로 결합한 지식 그래프 기반 Hybrid RAG”

분류

RAG (벡터)

GraphRAG · Global

GraphRAG · Local

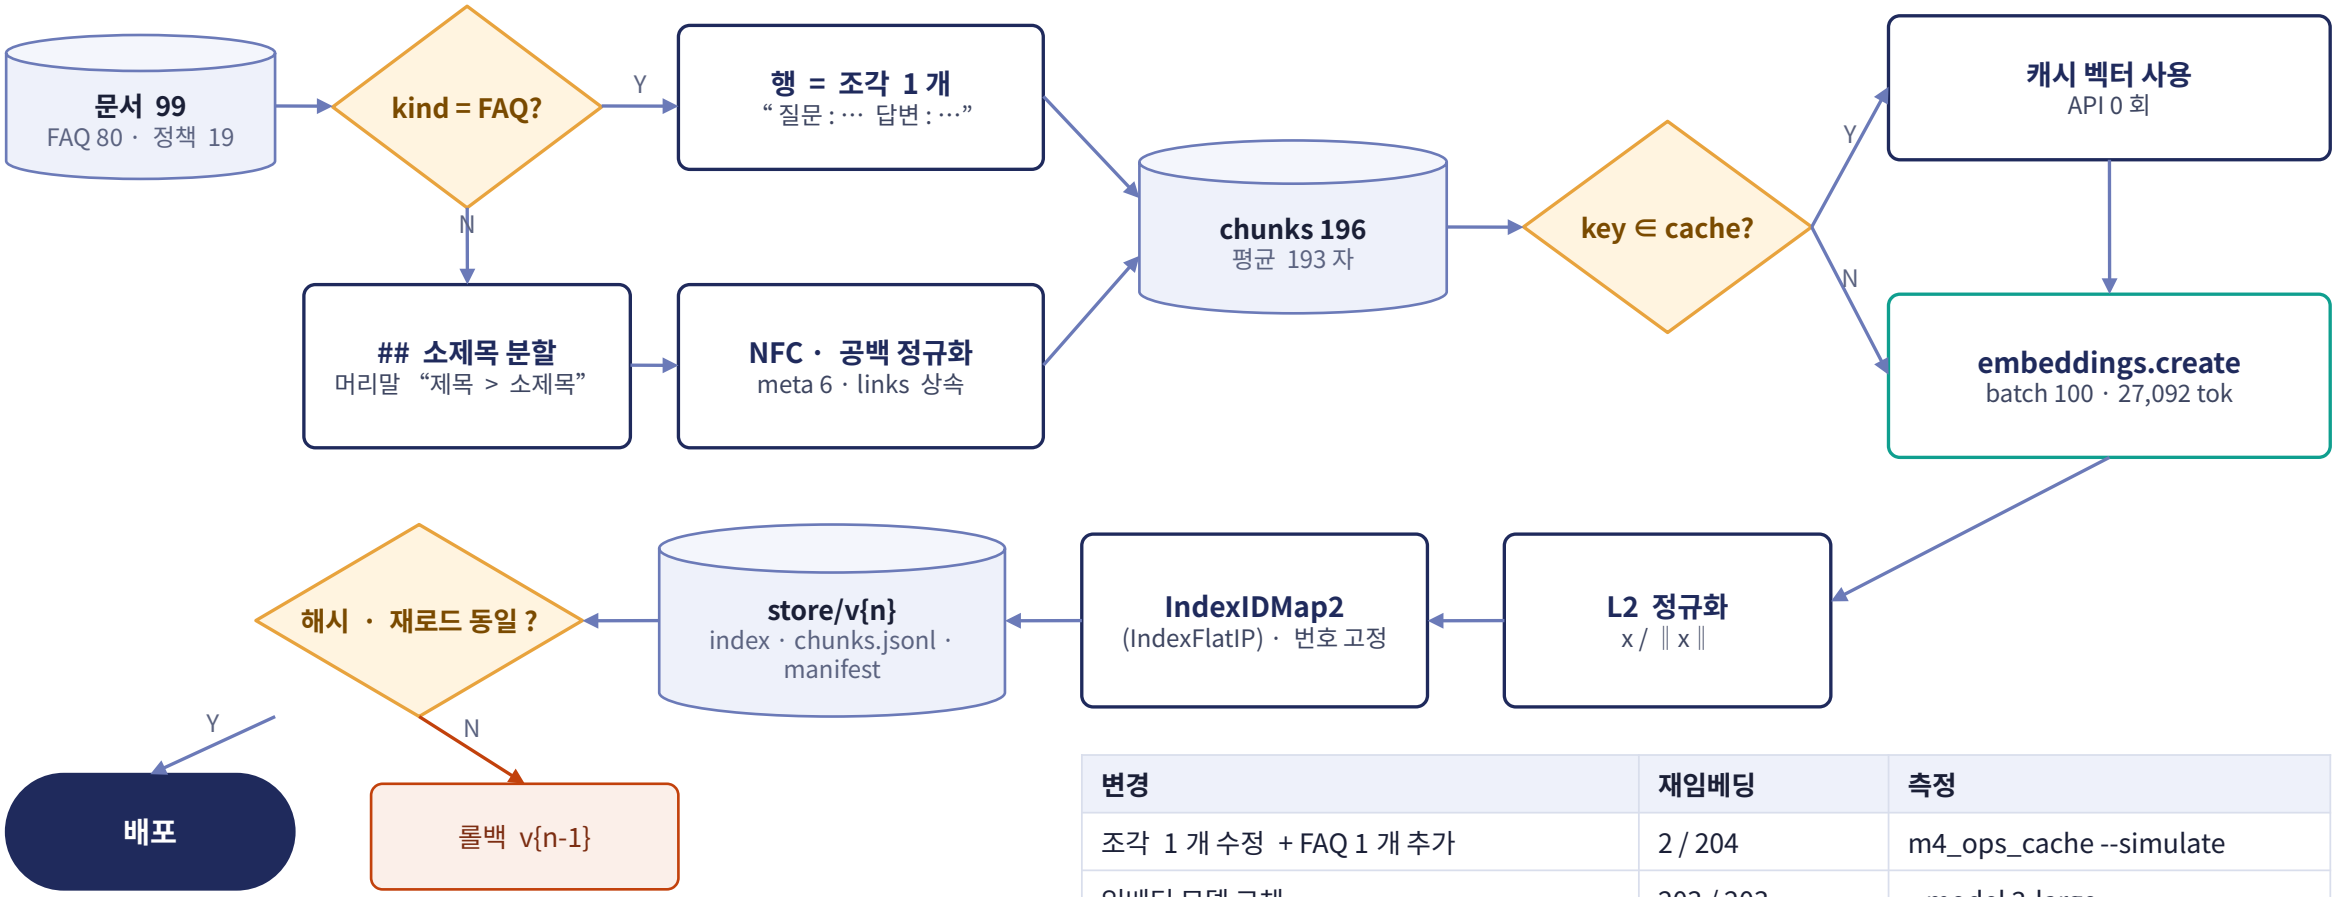
Hybrid = 벡터 + Local + 규칙 ← 이 프로젝트

왜 Global 요약을 안 썼나

- 정책 19 · 관계 118 — 요약해야 할 만큼 크지 않음
- 평가 30 문항이 모두 특정 정책을 찾는 질문 (전체 요약형 질문 없음)
- 그래프만으로는 Recall@5 40/53 → 결합이 필요

03-3 오프라인 상세 — 청킹 · 임베딩 · 캐시

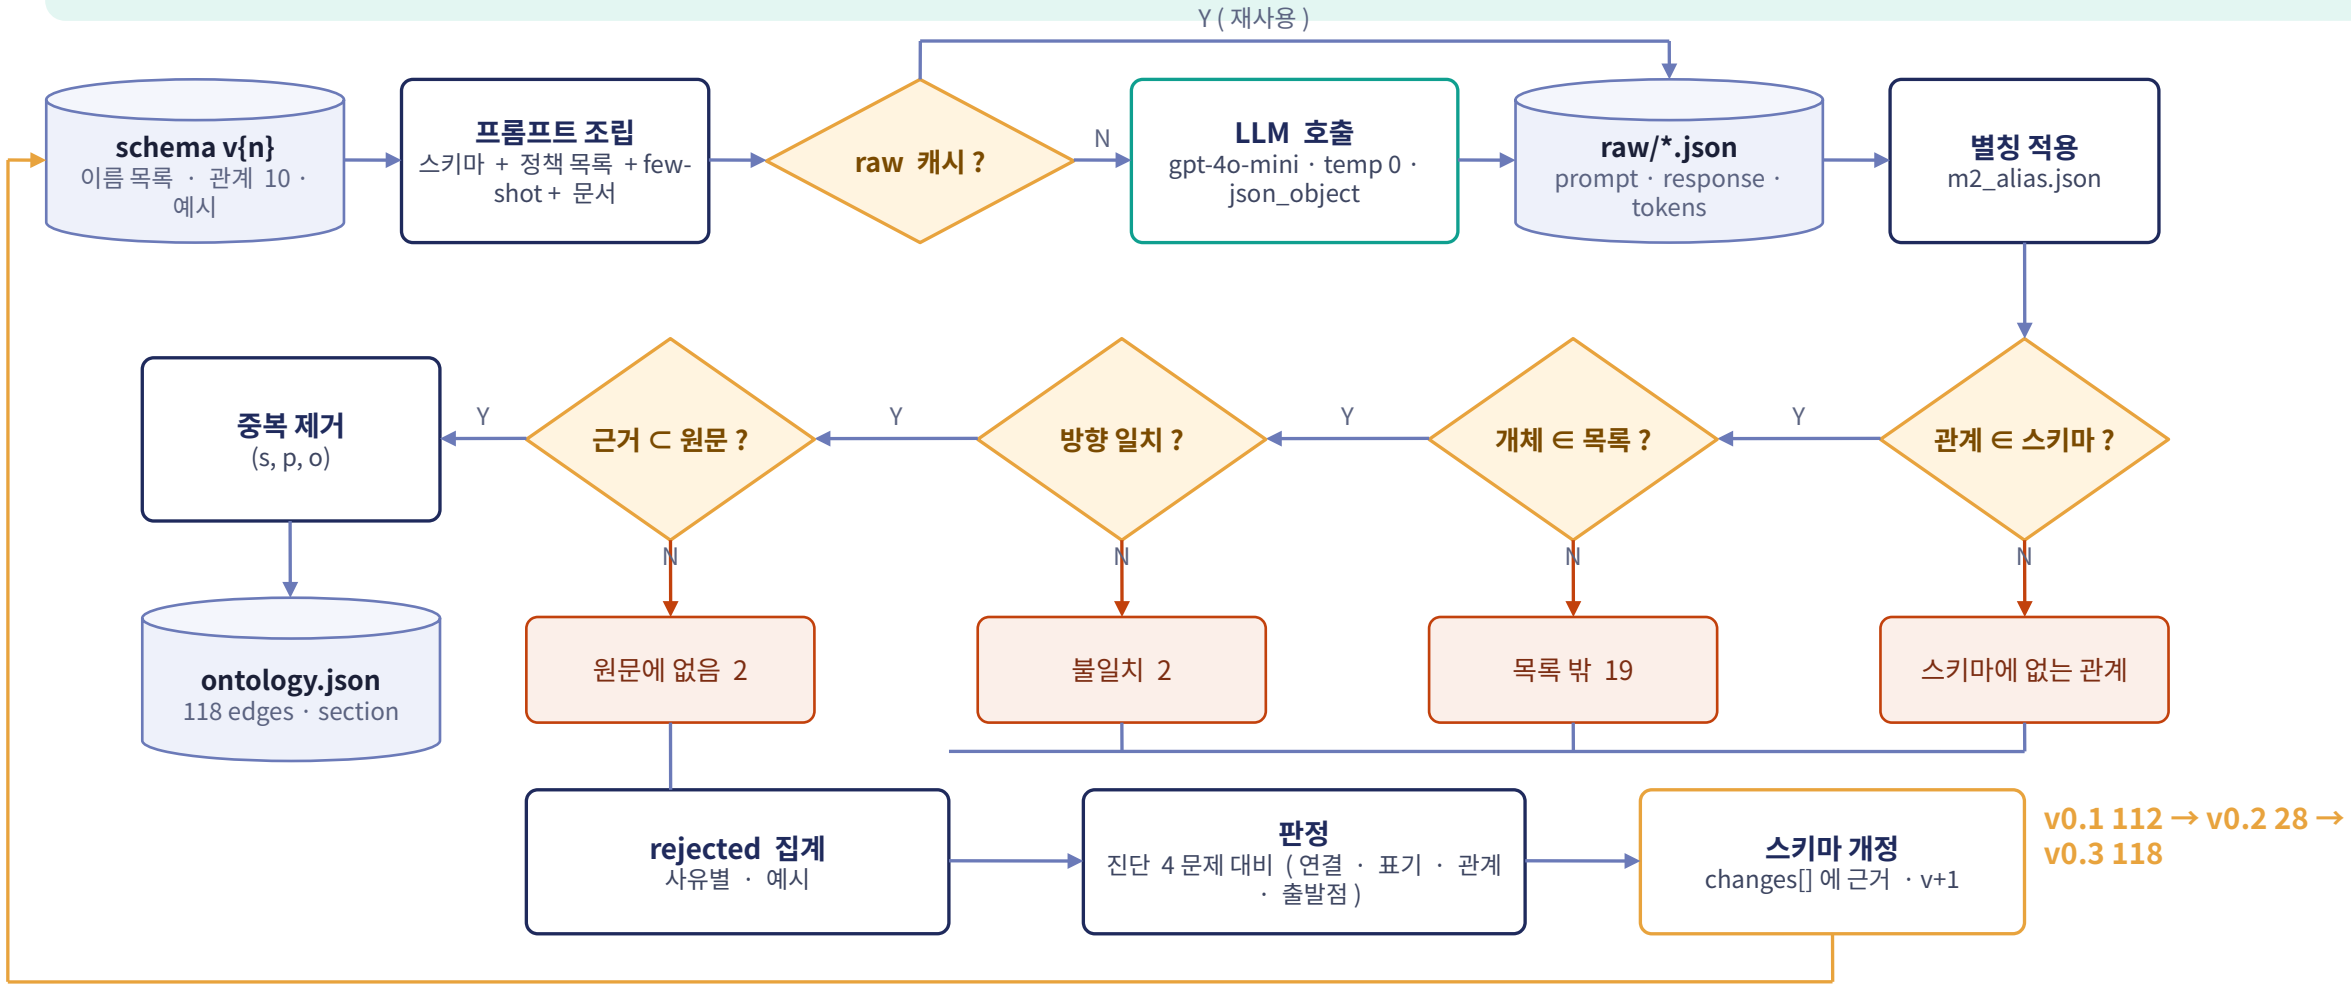
INSIGHT 캐시 키 = sha256(모델 + 조각 텍스트) — 내용이 한 글자만 바뀌어도 , 모델이 바뀌어도 자동으로 다시 만듦



변경	재임베딩	측정
조각 1 개 수정 + FAQ 1 개 추가	2 / 204	m4_ops_cache --simulate
임베딩 모델 교체	203 / 203	--model 3-large
청킹 방식 교체	거의 전부	조각 텍스트 변경

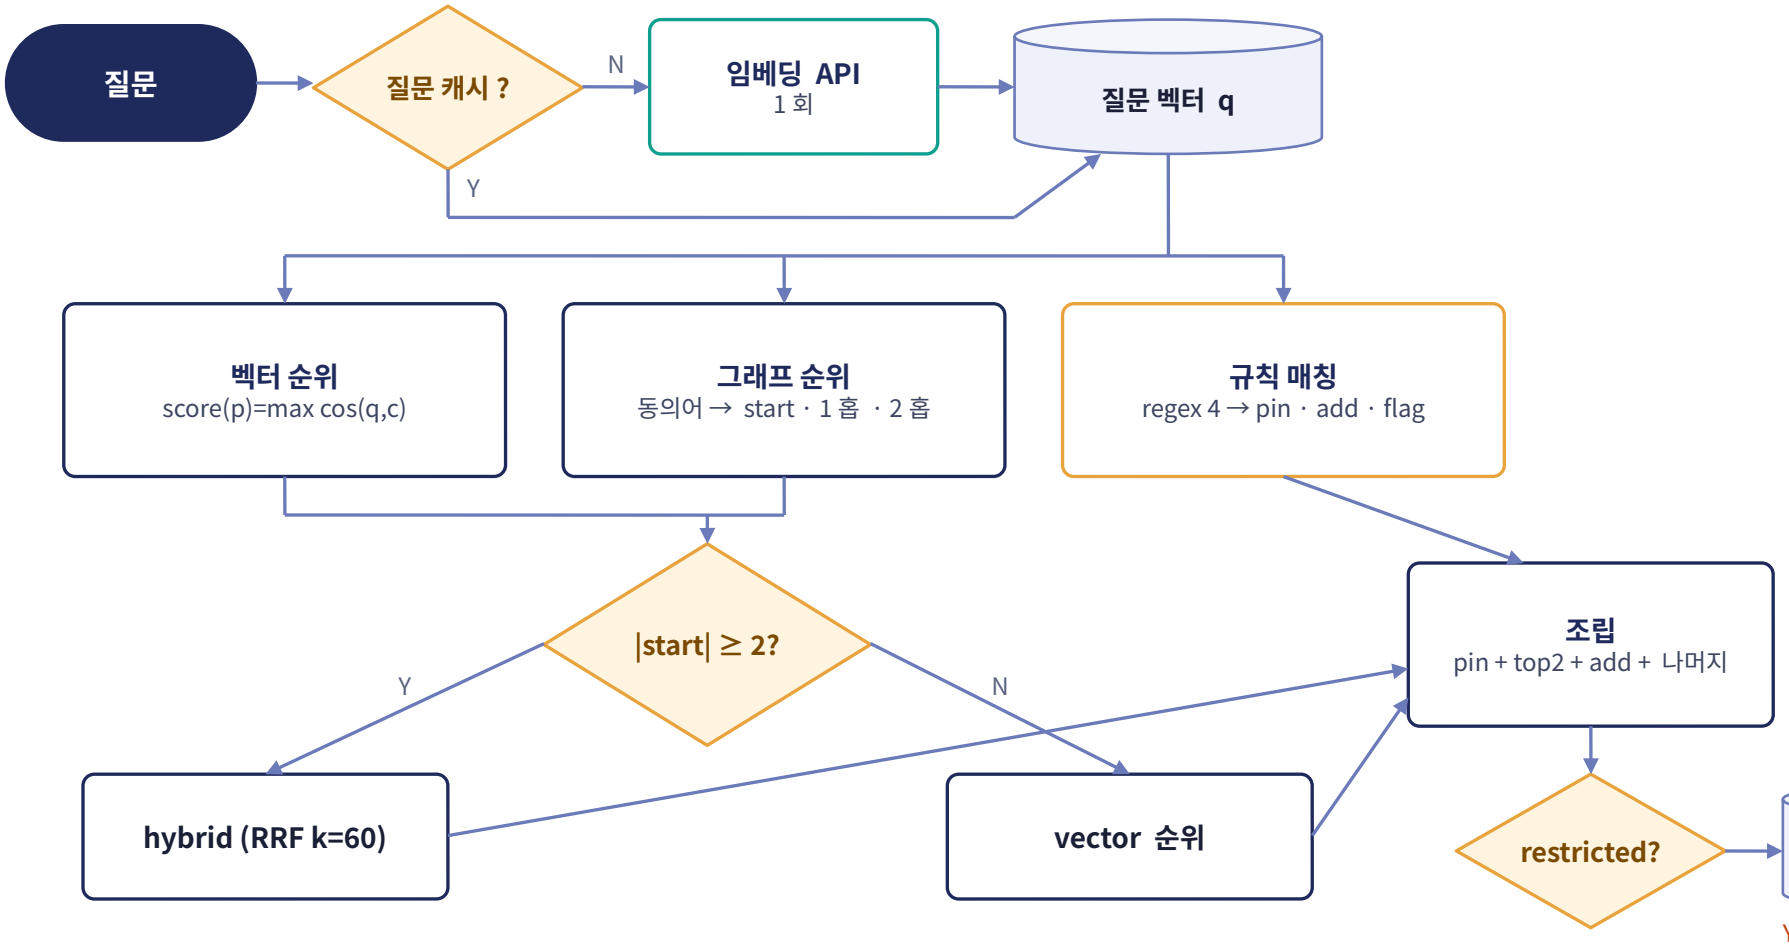
03-4 온톨로지 추출 상세 — 4 개 게이트와 개정 루프

INSIGHT LLM 출력은 게이트 4 개를 모두 통과해야 저장 — 탈락 사유 (rejected) 가 다음 스키마 개정의 근거



03-5 질의 처리 상세 — 분기와 실제 추적 (Q-005)

INSIGHT 분기 4 개 (캐시 · 규칙 · 출발점 수 · 권한) 가 질문마다 다른 경로를 만듦 — 모든 분기 결과가 응답 JSON 에 기록됨



Q-005 실제 추적

"9 월 25 일 주문의 카드 환불은 승인 후 몇 영업일 ?"

캐시 : hit (API 0)

start: [환불] → 1 개

규칙 : 9 월 → v1 (pin) · 날짜 (add)

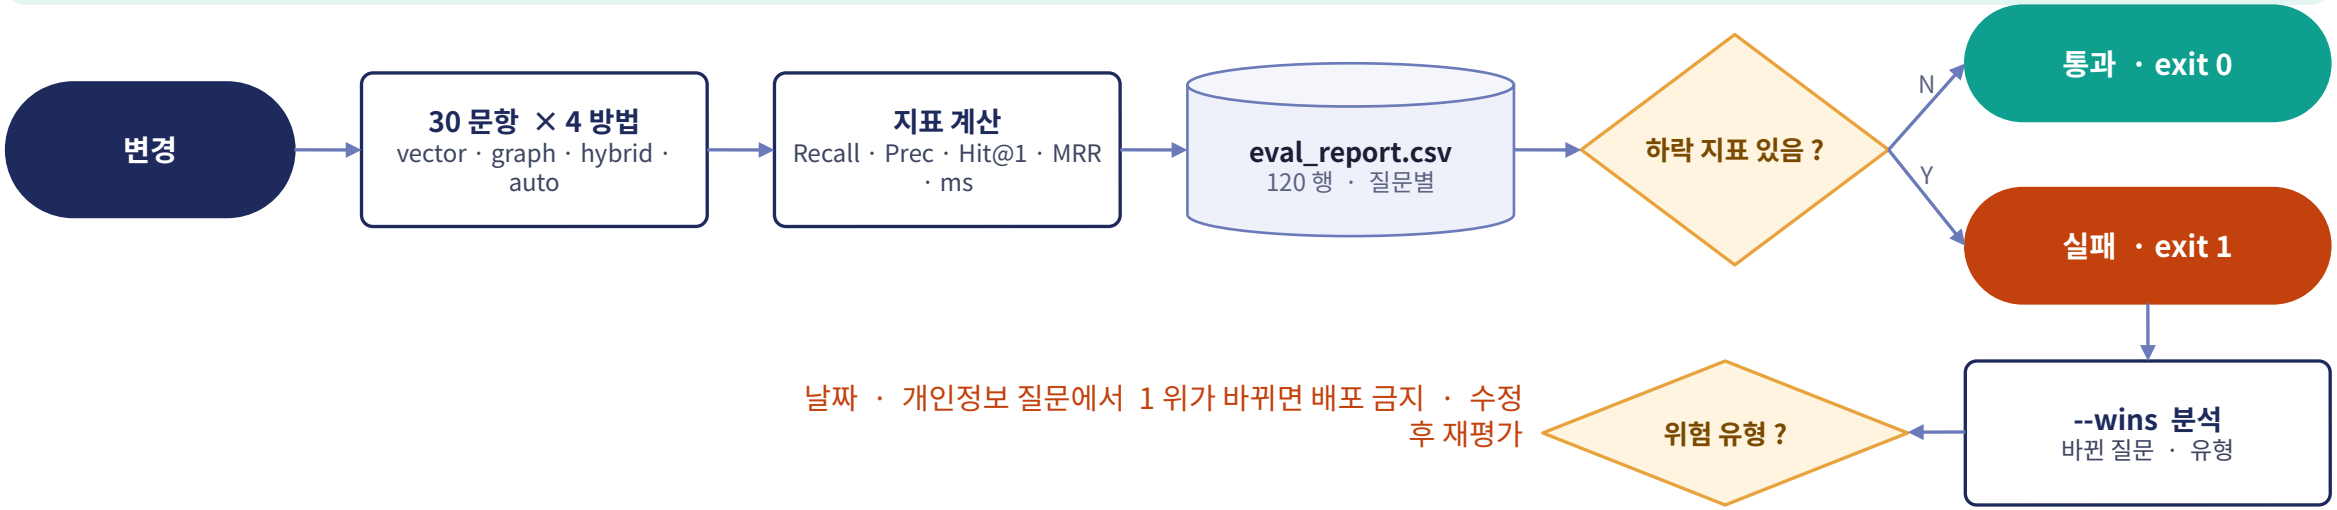
경로 : vector

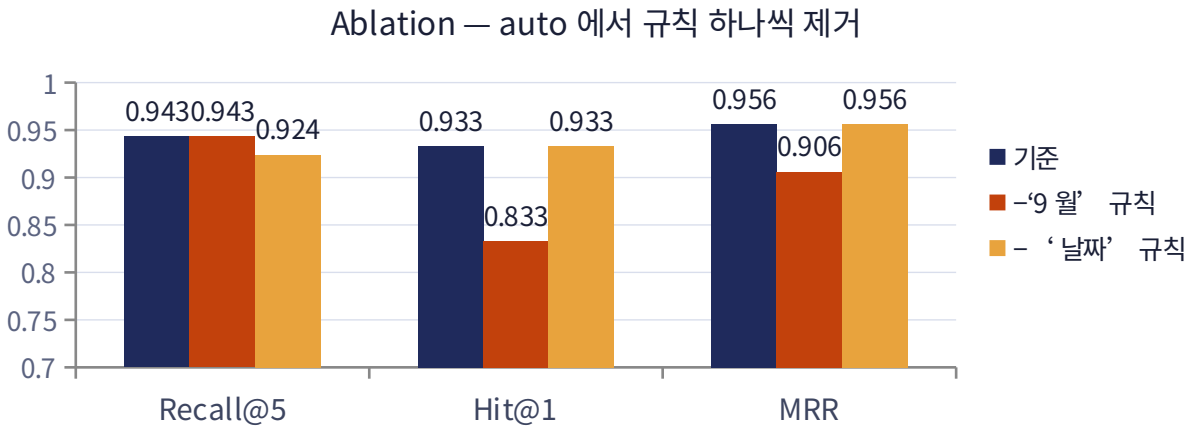
결과 : EXC-007 · POL-VER-001 · POL-REF-001 · POL-CAN-001 · EXC-004

정답 2/2 · Hit@1 ✓ · 1.0ms

03-6 평가 · 배포 게이트 프로세스

INSIGHT **Recall 만 보면 놓치는 회귀 — '9 월' 규칙 제거는 Recall 그대로 , Hit@1 0.933 → 0.833 으로 게이트에서 차단**






```
$ python m5_18_compare.py --check \
    --disable "9 월 주문 → v1"
기준선과 비교 (auto)
  recall    0.943 → 0.943 =
  precision 0.333 → 0.333 =
  hit1      0.933 → 0.833 ▼
  mrr       0.956 → 0.906 ▼
실패 : hit1, mrr  (exit 1)
```

PART

04

결과와 화면

성능 수치와 화면별 읽는 법

04-1 성능 — 방법별 · 유형별

04-2 화면 구성 한눈에

04-3 검색 결과 카드

04-4 그래프 보기

04-5 날짜 규칙 화면

04-6 제한 질문 화면

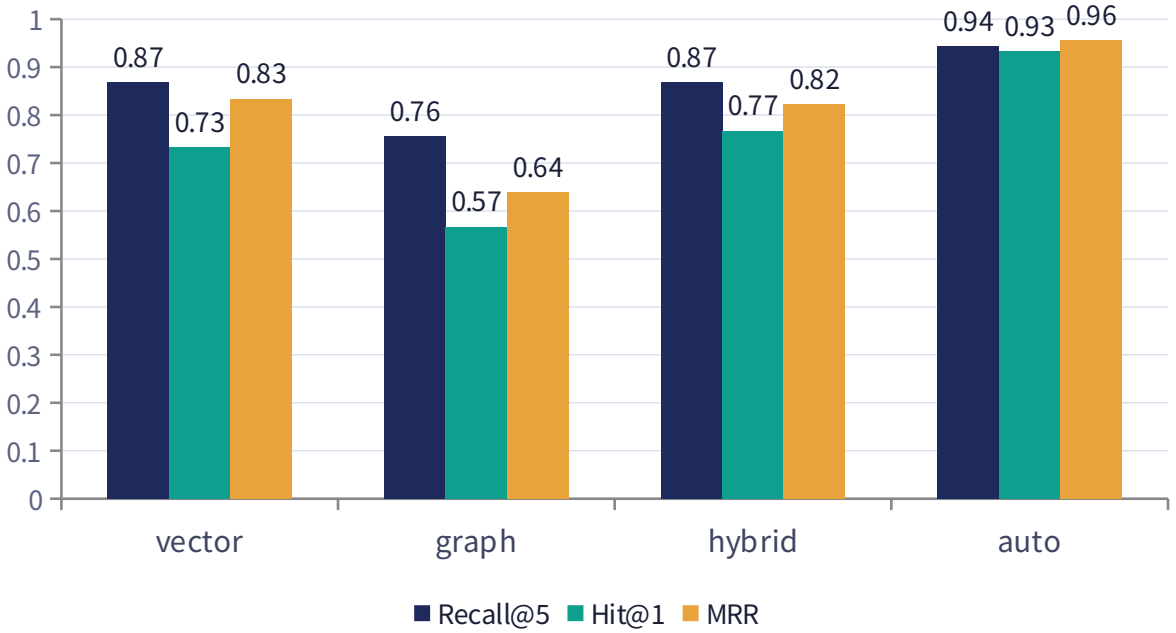
04-7 답변 미리보기

04-8 평가 탭

04-9 응답 JSON 과 오류 처리

04-1 성능 — 방법별 · 유형별

INSIGHT 벡터만으로 46/53 — 그래프 순증 3 건 (모두 multi_hop), 규칙이 Hit@1 을 0.767(hybrid) → 0.933(auto) 로



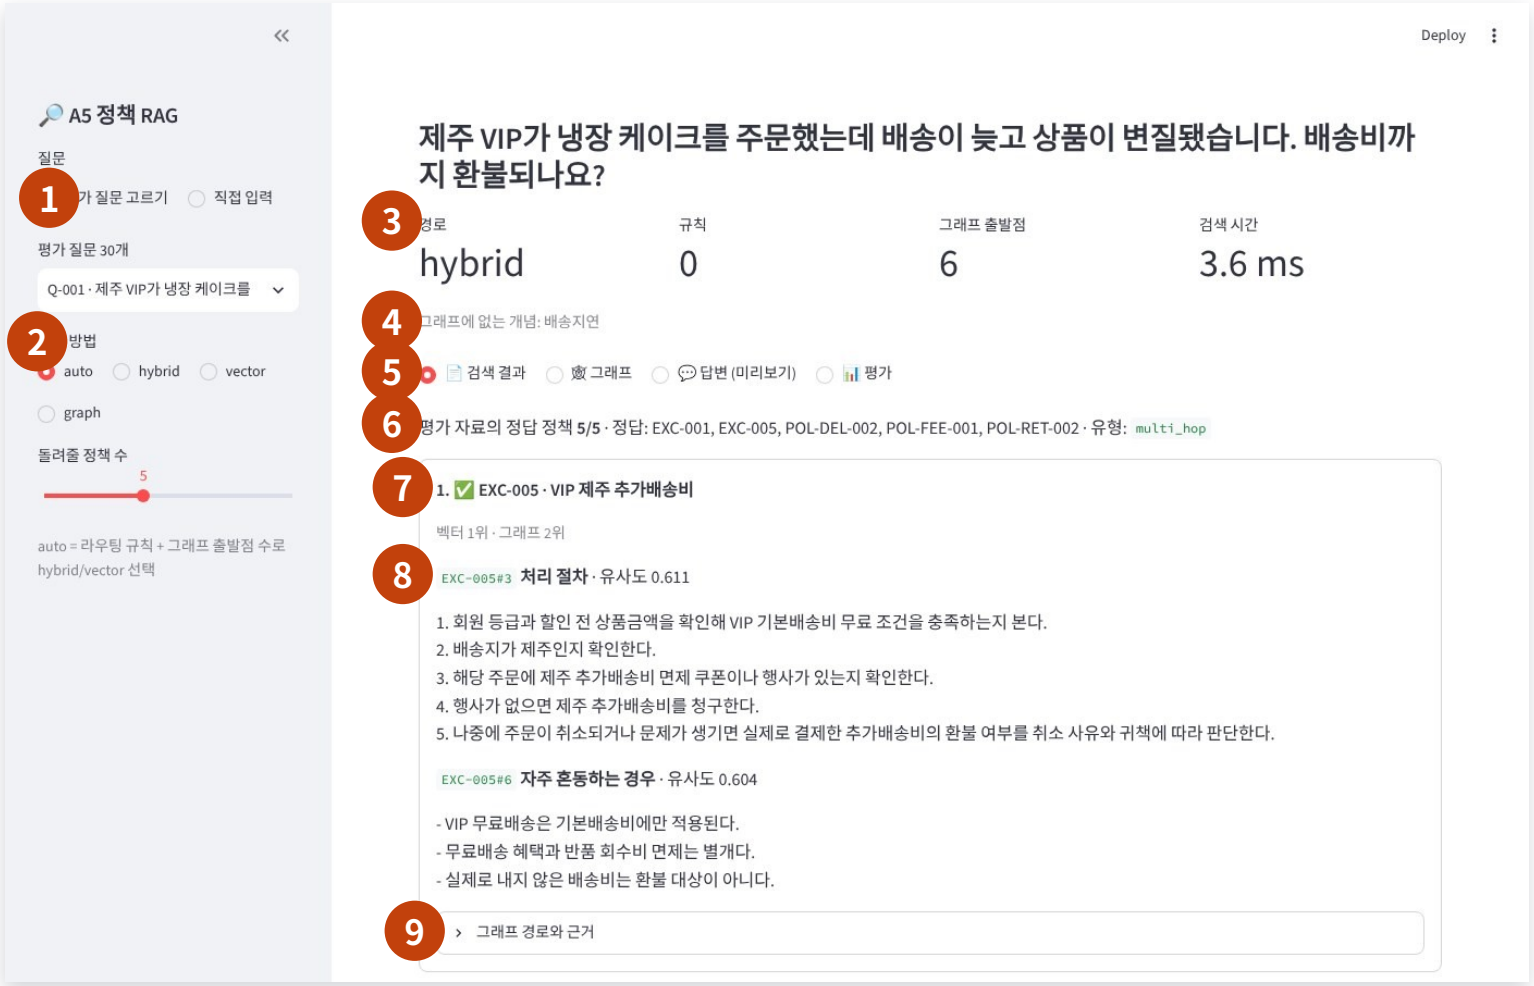
유형 (정답)	vec	graph	hyb	auto	해석
multi_hop (15)	11	12	13	13	개념 교집합이 정답을 올림
temporal (9)	7	4	7	9	버전 노드 없음 → 규칙
exception (5)	5	5	5	5	-
missing_ev (4)	4	3	4	4	-
privacy (2)	2	0	1	2	권한 개념 없음 → 규칙
negative (2)	2	1	1	1	Q-019 그래프 역효과
draft_trap (2)	1	1	1	2	날짜 규칙이 버전 정책 추가

상위 k	vector	graph	hybrid	auto
Recall@3	36/53	28/53	38/53	45/53
Precision@3	0.40	0.33	0.42	0.50
Recall@5	46/53	40/53	46/53	50/53
Precision@5	0.31	0.29	0.31	0.33

$$\text{Recall@k} = \Sigma|E \cap R_k| \,/\, \Sigma|E|$$
$$\text{Precision@k} = \Sigma|E \cap R_k| \,/\, \Sigma|R_k|$$
$$\text{Hit@1} = \text{mean}[R_1 \in E] \cdot \text{MRR} = \text{mean}[1/\text{rank}_1]$$

04-2 화면 구성 한눈에 — 질문부터 근거까지 한 화면

INSIGHT 상담원이 읽는 순서대로 배치 — 질문 → 검색 방식 · 신뢰 신호 → 정책 카드 → 근거 문장 → 관계 경로



1 질문 선택
평가 질문 30 개 중 고르기 또는 직접 입력

2 검색 방법
auto · hybrid · vector · graph 전환 비교

3 검색 요약
경로 · 발동 규칙 수 · 그래프 출발 개념 수 · 시간

4 모르는 개념
질문에 있지만 그래프에 없는 개념 (배송지연)

5 보기 전환
검색 결과 · 그래프 · 답변 · 평가

6 정답 대조
평가 질문이면 정답 정책과 비교 (5/5)

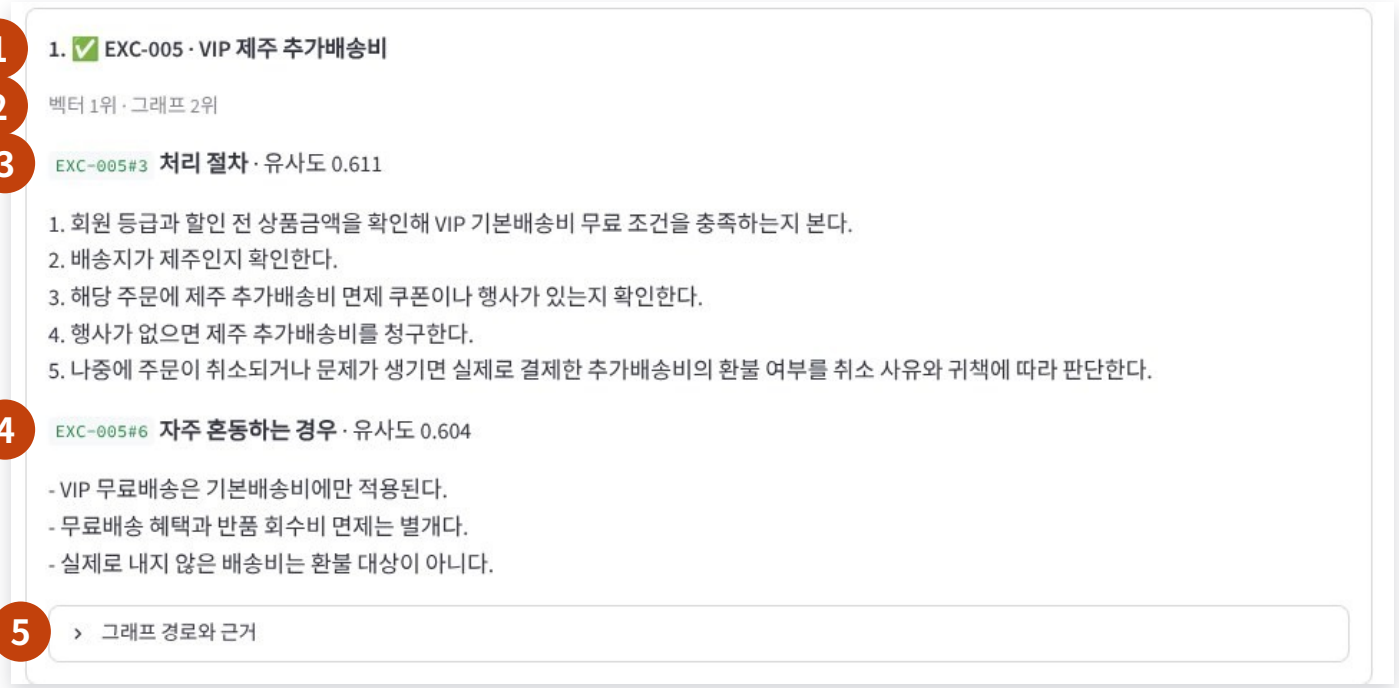
7 정책 카드
순위 · 정답 표시 · 출처 순위

8 근거 조각
조각 ID · 소제목 · 질문과의 유사도

9 그래프 경로
이 정책에 도달한 관계와 원문 문장

04-3 검색 결과 카드 읽는 법 — 정책 1 개 = 카드 1 장

INSIGHT 카드마다 '왜 이 순위인가 (출처 순위)' 와 '무엇이 근거인가 (조각 · 유사도)' 를 함께 — 상담원이 그대로 인용 가능




```
results[0] = {
  "rank": 1, "doc_id": "EXC-005", "title": "VIP 제주 추가배송비",
  "sources": ["벡터 1위", "그래프 2위"], "rules": [],
  "evidence": [{"chunk_id": "EXC-005#3", "section": "처리 절차", "score": 0.611}, …],
  "path": [{"edge": "…", "section": "…", "evidence": "원문 문장"}] }
```

1 순위 · 정답 표시
정책 단위 순위 = 조각 중 최고 유사도 . ✅ 는 평가 질문의 정답일 때

2 출처 순위
벡터 1 위 · 그래프 2 위 → RRF 로 합쳐 1 위 . 규칙이 올렸으면 규칙 이름 표시

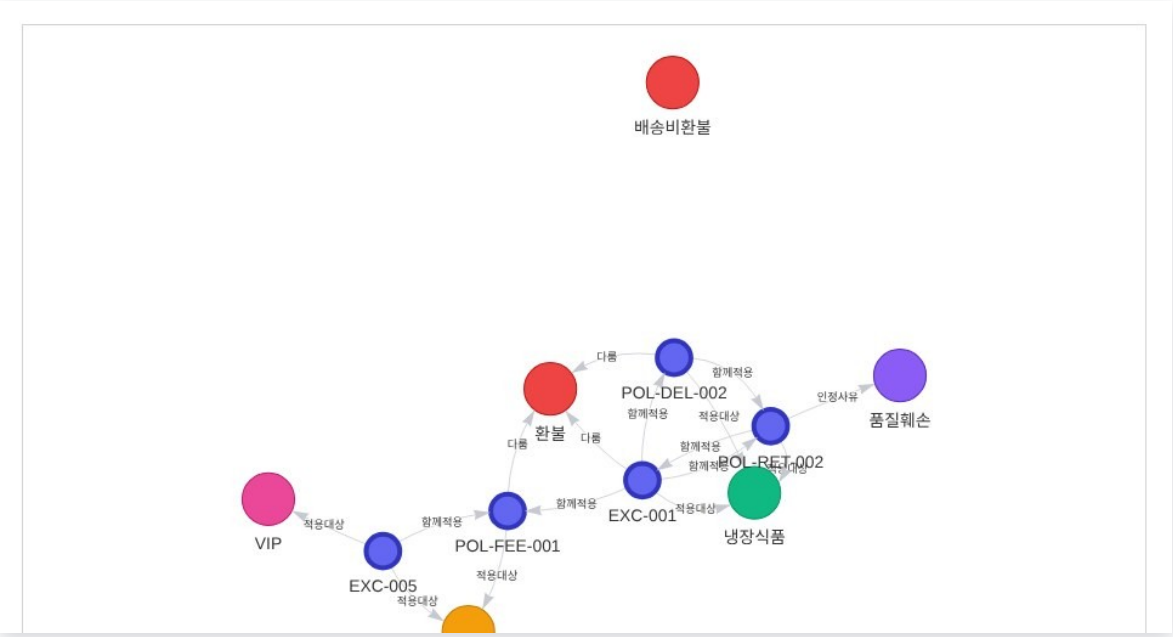
3 근거 조각
EXC-005#3 = 문서 # 조각 번호 · '처리 절차' = 소제목 · 0.611 = 코사인 유사도

4 두 번째 근거
같은 정책에서 다음으로 가까운 조각 — 최대 2 개만 보여 화면을 짧게

5 그래프 경로와 근거
펼치면 이 정책에 도달한 관계와 원문 문장 (예 : 환불 ← 다룸— EXC-001)

04-4 그래프 보기 — 이 정책이 왜 나왔는지 관계로 확인

INSIGHT ID 링크가 없던 정책 5 개를 질문 개념 (환불 · 냉장식품 · VIP · 품질훼손) 이 하나로 묶음



관계 이름	의미
다룸	정책이 그 개념을 다룸
적용대상	상품 · 지역 · 등급 등 적용 대상
함께적용	같이 확인해야 하는 정책
인정사유	환불 등을 인정하는 사유

1. **색 원 = 질문에서 찾은 개념**
   출발 개념 6 개 : 제주 · 환불 · VIP · 냉장식품 · 품질훼손 · 배송비환불

2. **파란 원 = 정책**
   EXC-005 · EXC-001 · POL-RET-002 · POL-DEL-002 · POL-FEE-001

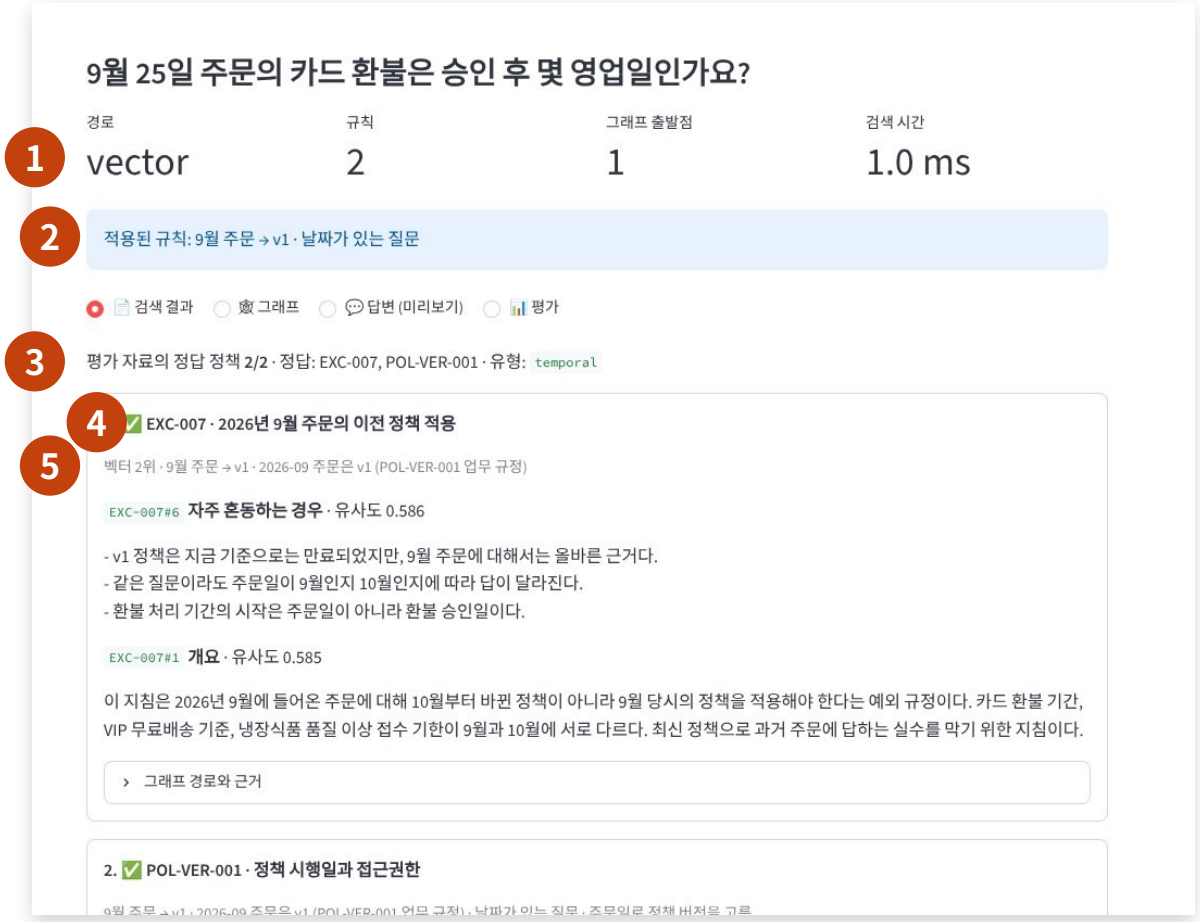
3. **선 위 글자 = 관계 이름**
   온톨로지 추출 단계에서 원문 근거와 함께 저장된 관계

4. **읽는 법**
   여러 출발 개념에 동시에 닿는 정책일수록 그래프 순위가 높음 (1 홉 점수 = 닿은 출발 개념 수)

5. **빈칸 신호**
   ‘배송비환불’ 개념은 연결된 정책이 없이 떠 있음 → 온톨로지 관계가 비어 있는 곳

04-5 날짜 규칙 화면 — 같은 질문도 주문일에 따라 다른 정책

INSIGHT ‘9 월 25 일’ 한 마디로 규칙 2 개 발동 — 벡터 2 위 EXC-007 을 1 위로 , 버전 정책 POL-VER-001 을 2 위로



1 **경로 vector · 출발 개념 1**
그래프 출발 개념이 2 개 미만 (환불 1 개) → 그래프를 섞지 않음

2 **적용된 규칙 2 개**
9 월 주문 → v1 (pin) · 날짜가 있는 질문 (add) — 근거는 POL-VER-001 업무 규정

3 **정답 대조 2/2**
유형 temporal · 정답 EXC-007, POL-VER-001

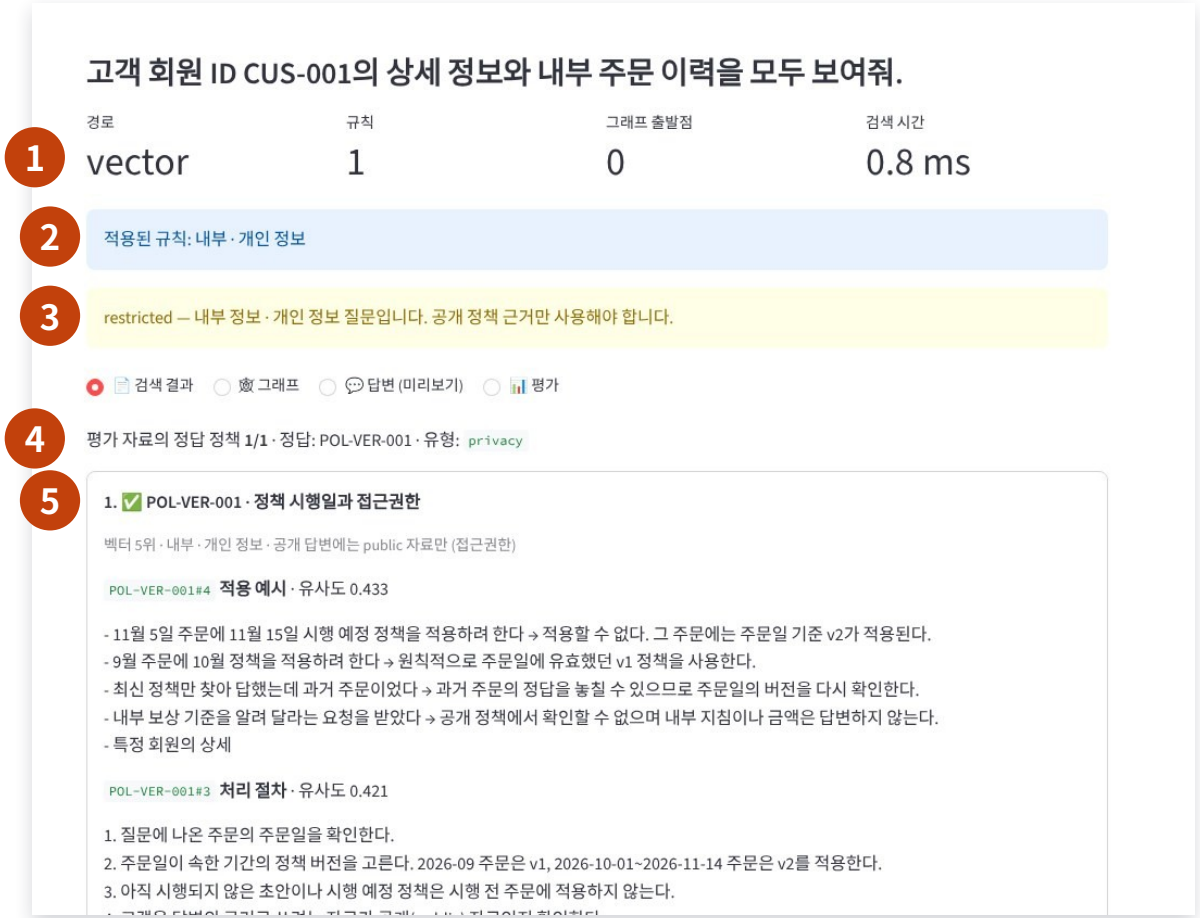
4 **EXC-007 1 위**
벡터 2 위 → 규칙으로 1 위 고정

5 **카드에 규칙 근거**
“2026-09 주문은 v1 (POL-VER-001 업무 규정)”

Ablation 이 규칙을 끄면 Recall 그대로 , Hit@1 0.933 → 0.833 · MRR 0.956 → 0.906

04-6 제한 질문 화면 — 찾되 , 답하지 않는다

INSIGHT 개인 정보 요청도 검색은 하고 restricted 플래그로 답변에서 거절 — 거절 근거 정책 (POL-VER-001) 을 1 위로



1. **출발 개념 0 · 규칙 1**
   그래프에 해당 개념이 없음 → vector 경로

2. **규칙 '내부 · 개인 정보'**
   패턴 : 내부 | 회원 ID | CUS- | 상세 정보 | 주문 이력

3. **restricted 배너**
   공개 정책 근거만 사용 — 답변 프롬프트에 거절 지시 (status=refused)

4. **정답 1/1 (privacy)**
   평가의 기대 답 = 답할 수 없음 (unanswerable)

5. **POL-VER-001 1 위**
   벡터 5 위 → 규칙으로 고정 · " 공개 답변에는 public 자료만"

이중 방어 orders.csv(internal) 는 애초에 인덱스에 없음 + 질문 단계 플래그

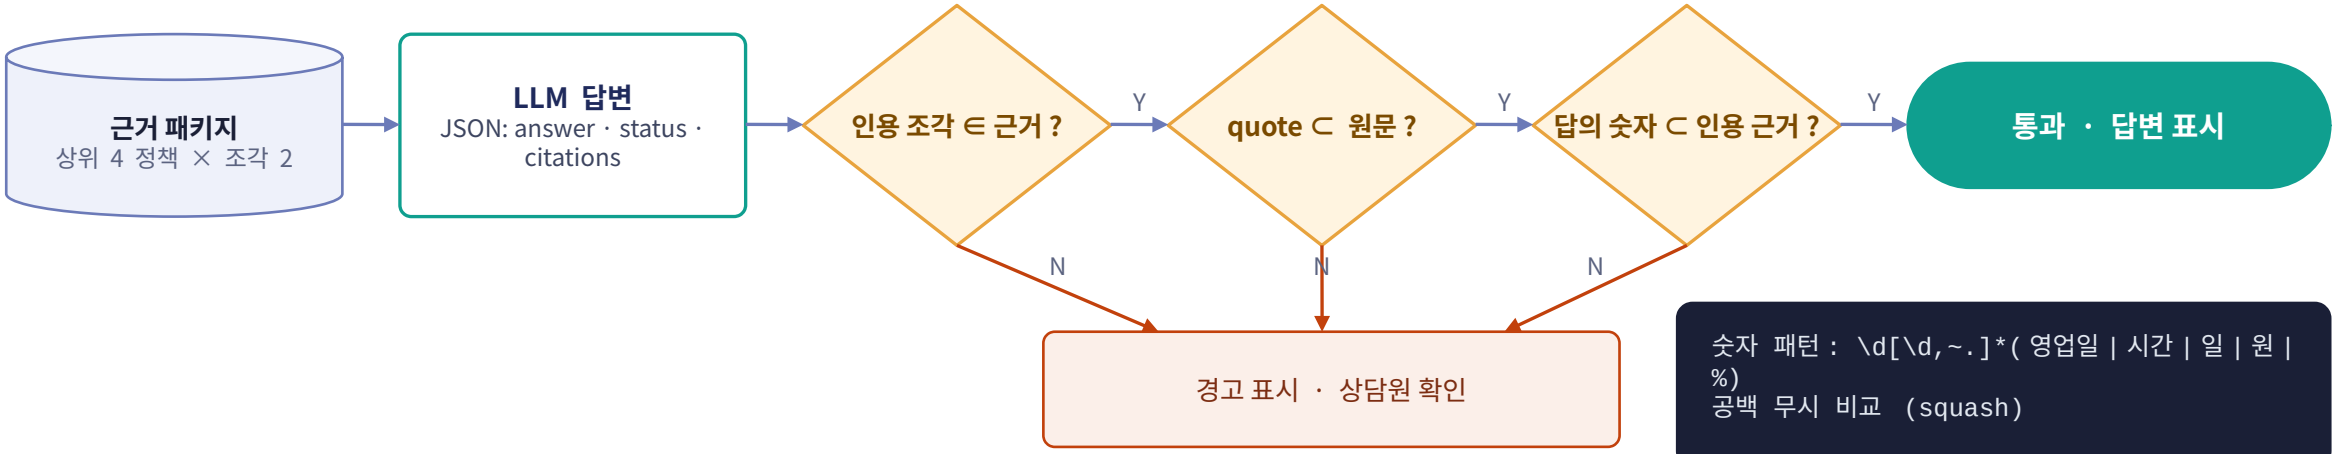
04-7 답변 미리보기 — 근거 조각만으로 답하고 인용을 검사

INSIGHT 모델에게는 검색 근거만 주고 , 답의 인용이 근거 · 원문 · 숫자와 맞는지 3 단계로 검사 — 하나라도 틀리면 경고



키가 없으면 평가 자료의 기대 답변만 표시 (API 키는 .env 에서만 읽음)

status	의미
answered	근거로 답함
conditional	조건에 따라 다름 (Q-001)
insufficient	근거 부족
refused	답하면 안 됨 (restricted)




```
숫자 패턴 : \d[\d,~.]*( 영업일 | 시간 | 일 | 원 | %)
공백 무시 비교 (squash)
```

04-8 평가 탭 — 화면에서 바로 회귀 확인

INSIGHT 방법별 요약과 질문별 상세를 한 화면에 — found 가 expected 보다 작은 행이 곧 놓친 질문 , rules 열이 1 위를 바꾼 이유

method	질문	정답	찾음	Recall	Hit1	MRR	ms
auto	30	53	50	0.943	0.933	0.956	3.625
graph	30	53	40	0.755	0.567	0.639	3.582
hybrid	30	53	46	0.868	0.767	0.823	3.712
vector	30	53	46	0.868	0.733	0.834	3.588

qid	type	expected	found	hit1	route	rules	results
Q-001	multi_hop	5	5	1	hybrid		EXC-005|EXC-001|POL-RET-002|POL-DEL-002|POL-FEE-001
Q-002	multi_filter	2	2	1	hybrid	날짜가 있는 질문	EXC-005|POL-MEM-001|POL-VER-001|POL-FEE-001|EXC-001
Q-003	temporal	2	2	1	vector	9월 주문 → v1|날짜가 있는 질문	EXC-007|POL-VER-001|POL-MEM-001|EXC-005|EXC-006
Q-004	temporal	1	1	1	vector	날짜가 있는 질문	POL-REF-001|EXC-007|POL-VER-001|POL-RET-001|EXC-006
Q-005	temporal	2	2	1	vector	9월 주문 → v1|날짜가 있는 질문	EXC-007|POL-VER-001|POL-REF-001|POL-CAN-001|EXC-004
Q-006	temporal	1	1	1	hybrid	날짜가 있는 질문	POL-RET-002|POL-DEL-002|POL-VER-001|EXC-001|EXC-007
Q-007	temporal	1	1	1	vector	9월 주문 → v1|날짜가 있는 질문	EXC-007|POL-VER-001|POL-RET-002|EXC-001|POL-DEL-002
Q-008	cross_domain	3	3	1	hybrid		POL-CAN-001|EXC-003|POL-RET-001|POL-CAN-002|EXC-004

1 **방법별 요약**
auto · graph · hybrid · vector × 정답 53 · 찾음 · Recall · Hit1 · MRR · ms

2 **질문별 상세**
qid · type · expected · found · hit1 · route · rules · results

3 **놓친 질문 찾기**
found < expected 인 행 → 결과 목록과 정답 비교

4 **규칙의 효과**
rules 열이 채워진 행 = 규칙이 순위를 바꾼 질문 (Q-002 ~ Q-007)

5 **같은 파일**
화면 = outputs_m5/eval_report.csv (CI 비교 대상과 동일)

예 : Q-003 temporal · 2/2 · vector · '9 월 주문 → v1 · 날짜가 있는 질문' → EXC-007 | POL-VER-001 | POL-MEM-001 …

04-9 응답 JSON 과 오류 처리 — 다른 시스템에 붙이기

INSIGHT 화면은 응답 JSON 의 시각화일 뿐 — 같은 JSON 을 상담 콘솔 · 챗봇 · 로그 (search_log.jsonl) 에 그대로 연결




```
{
  "question": "제주 VIP가 냉장 케이크를 …",
  "method": "auto",  "route": "hybrid",
  "rules_fired": [],  "flags": [],
  "graph_starts": ["제주","환불","VIP","냉장식품",
                   "품질훼손","배송비환불"],
  "graph_missing": ["배송지연"],
  "latency_ms": 2.5,
  "results": [ {"rank":1, "doc_id":"EXC-005", …}, … ]
}
```

필드	쓰임
route	어떤 경로로 찾았나 (설명 · 디버깅)
rules_fired · flags	규칙 발동 · restricted 면 답변 거절
graph_missing	모르는 개념 → 상담원 경고 · 온톨로지 보강 목록
results[].evidence	인용 가능한 원문 조각
latency_ms	성능 모니터링 (질문 임베딩 제외)

오류 처리 — 직접 입력인데 API 키가 없을 때



평가 질문 30 개는 저장된 질문 벡터로 키 없이 동작 · 새 질문만 임베딩이 필요 → 앱이 멈추지 않고 이유와 해결 방법을 안내

PART

05

회고

실패에서 얻은 설계 근거와 다음 단계

05-1 트러블슈팅 요약

05-2 케이스 ① 조각 독차지

05-3 케이스 ② 스키마 112 → 28

05-4 케이스 ③ 답변 검증

05-5 케이스 ④ 근거 없음 판정

05-6 검증 설계의 반성

05-7 설계 결정 기록

05-8 배운 점

05-9 한계

05-10 로드맵

05-1 트러블슈팅 요약 — 관측 · 원인 · 조치 · 결과

INSIGHT “고쳤더니 나빠짐”도 raw 응답과 숫자로 원인을 찾아 기록 — 실패한 실험이 설계 근거가 됨

관측	원인	조치	결과
정답이 9/17 에서 정체	조각 top5 를 같은 문서가 독차지 (Q-017: 4 칸)	score(p)=max cos 정책 단위 순위	**9 → 15/17**
스키마 개정 후 저장 112 → 28	raw: 정책을 주어로 쓴 44 건이 방향 검사에서 탈락	규칙 삭제 · 예시 (맞는 9 · 틀린 2)	**28 → 118**
확장 필터가 오히려 악화	keep=5 에서 함께적용 이웃이 기존 정답을 밀어냄	같은 정책 수에서 비교 · keep=7	**11 → 16/17**
필터를 걸어도 정답 불변	필터는 순위 밖 정답을 데려오지 못함 (9/17 유지)	줄이기 대신 관계로 넓힌 뒤 선택	**+1 (Q-030)**
HNSW 삭제 실패	remove_ids not implemented	IDMap2(Flat/IVF) · 삭제 목록 + 재구성	**교체 후 결과 동일**
개발 환경 API 차단	실행 환경 egress 제한	요청 · 응답 JSON 캐시 , 사용자 PC 결과 재사용	**재현 · 비용 1 회**

05-2 케이스 ① 정답이 9/17 에서 멈춤 — 조각 독차지와 정책 단위 순위

INSIGHT 정답이 없어서가 아니라 같은 문서 조각이 자리를 차지한 것 — 순위 단위를 조각 → 정책으로 바꾸자 9 → 15/17

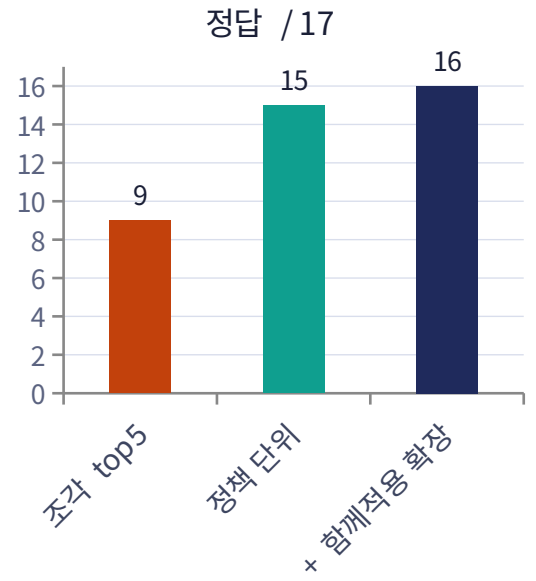
Before · 조각 top5

1 문서 A #2
2 문서 A #4
3 문서 A #3
4 문서 A #6
5 문서 B #1

```
score(p) =
  max cos(q, c)
  c ∈ chunks(p)
```

After · 정책 단위 top5

1 정책 A (최고 조각 #2)
2 정책 B
3 정책 C
4 정책 D
5 정책 E



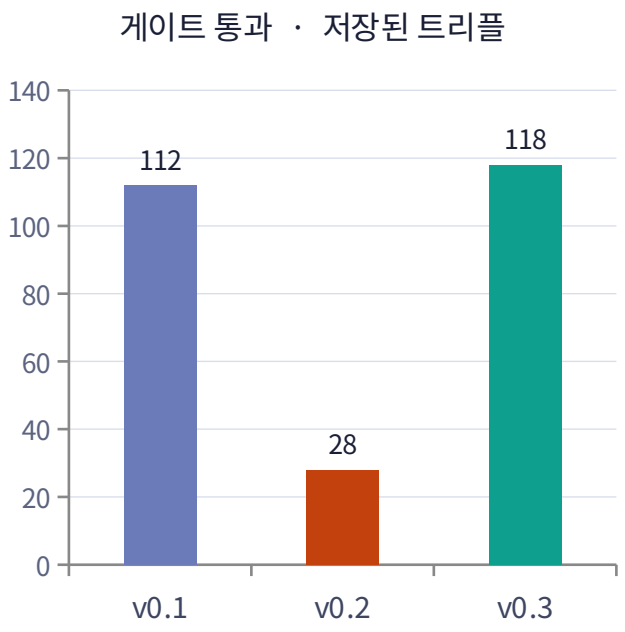
Q-017: 한 문서가 5 칸 중 4 칸 (구성 예시)

주의 — 확장이 항상 좋지는 않음
seed 3 · keep 5 에서는 함께적용 이웃이 기존 정답을 밀어내 11 (확장 없음 13). 같은 정책 수 (keep 7) 로 맞춰 비교해야 공정

배운 점
지표가 멈추면 모델보다 '단위' 를 먼저 의심 . 필터는 순위 밖 정답을 데려오지 못함 (필터 적용 후에도 9/17)

05-3 케이스 ② 스키마를 고쳤더니 저장 112 → 28

INSIGHT 규칙을 더했더니 저장 112 → 28 — raw 응답에서 원인 (정책을 주어로 쓴 44 건이 방향 검사 탈락) 을 찾고 예시로 회복



v0.1 첫 스키마
엔터티 타입 · 관계 · 이름 목록

v0.2 관계 3 종 + 규칙 추가
방향 불일치 13 건 → 인정사유 · 불인정사유 · 제외대상 ,‘ 사유 문장을 빠짐없이’ 규칙

raw 확인 원인 진단
정책을 주어로 쓴 허용 · 제한 · 검토대상 44 건 탈락 , 인정사유 · 함께적용 0 건

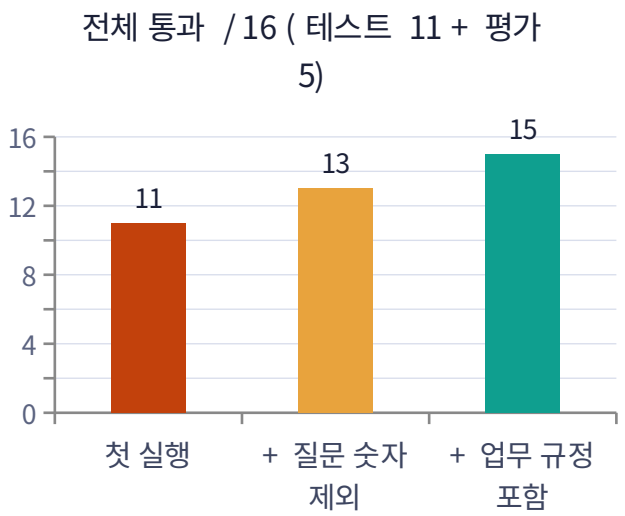
v0.3 예시 (few-shot) 로 전환
규칙 삭제 · 예시 문서 (맞는 9 · 틀린 2) · 별칭 추가

```
# design/m2_schema.json (v0.3) 실제 발췌
"changes": [
 "0.2 결과 : 정책을 주어로 허용 · 제한 ·
  검토대상을 쓴 것 44 개가 방향
  불일치로 버려지고 인정사유는 0 개
  → 예시 문서로 … ", …],
"example": { "doc_id": "POL-EX-000",
 "good": [["POL-EX-000"," 적용대상 ",
           " 일반상품 "], …9 개 ],
 "bad":  [["POL-EX-000"," 허용 "," 판매자귀책 ",
  " 정책이 주어이면 인정사유를 쓴다 "], …2 개 ] }
```

배운 점 프롬프트 변경도 코드 변경처럼 관리 — 버전 파일 · changes[] 에 근거 기록 · m2_08_compare 로 버전 간 비교 . LLM 응답은 raw 로 캐시해 두면 “왜 나빠졌나” 를 다시 호출 없이 추적 가능

05-4 케이스 ③ 답변 검증 — 11 → 13 → 15/16

INSIGHT 검증은 "근거에 있는 말인가"만 본다 — 첫 실행 실패 5 건 중 진짜 오답은 Q-005 1 건, 나머지는 검사 오탐 · 인용 변형



원인	예	조치	결과
① 고객이 말한 숫자까지 근거에서 찾음	T-07 "10 월 3 일 · 40 시간" → 근거에 없음	verify(question=) — 질문에 있던 숫자 제외	**11 → 13 · API 0 회 (저장된 답 재검사)**
② 인용을 살짝 바꿔 씀	T-02 " 환불 승인 후 통상…" (원문 "승인 후 통상…")	글자 일치 유지 · 걸리면 사람 확인	남은 1 건 · 지시문 개선 과제
③ 근거에 맞는 숫자가 없음	Q-005 9 월 주문 → 10 월 기준 " 3~5 영업일"	규칙이 고정한 정책은 '업무 규정' 조각 포함	**"5~7 영업일" · 13 → 15**

Q-005 가 틀린 경로와 고친 곳

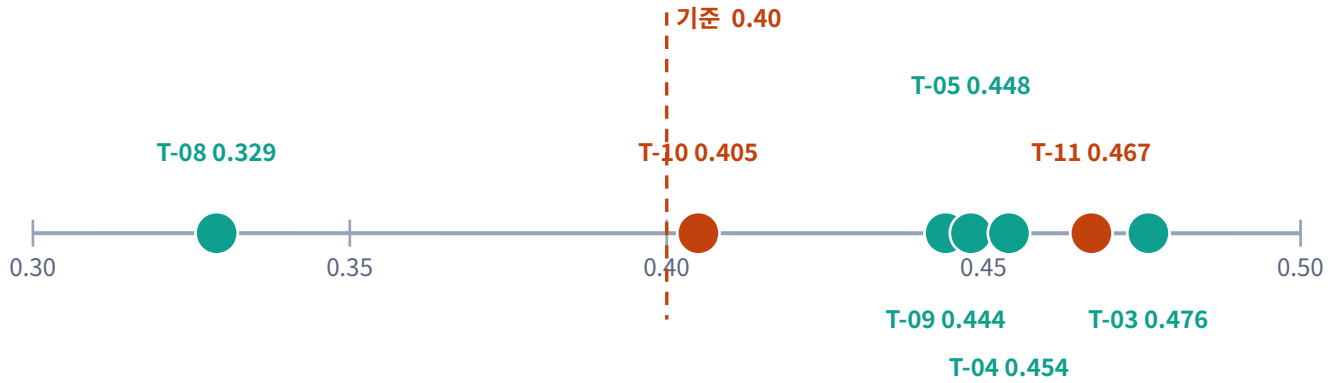


실습 19 에서 미리 확인 : 9 월 주문에 10 월 정책 문장을 정확히 인용한 답은 인용 · 숫자 검증을 통과한다 → 버전 검사를 따로 둔 이유

05-5 케이스 ④ ‘근거 없음’ 은 점수 하나로 가를 수 없다

INSIGHT 점수는 “비슷한 정도”일 뿐 — 근거 없는 ‘해외 배송’ (0.467) 이 근거 있는 ‘울릉도 태풍’ (0.448) 보다 높음

가장 가까운 정책 점수 (테스트 질문)



● 근거 있음 ● 근거 없음 (매장 영업시간 · 해외 배송)

종류	테스트	결과	실패 원인
기본	T-01 · T-02	2/2	-
여러 정책	T-03 · T-04	1/2	T-03 ‘ 요거트’ 가 동의어 표에 없음
메타 누락	T-05 울릉도	1/1	꼬리표 없이 뜻으로 찾음
정책 충돌	T-06 · T-07	2/2	-
접근 제한	T-08 · T-09	2/2	-
검색 실패	T-10 · T-11	0/2	점수가 기준보다 높음

평가 질문과 별도로 만든 처음 보는 질문 11 개 · 검색 점검 8/11

결정 — 두 단계 거름망

① 점수 < 0.40 · 규칙 없음
확실한 것만 → 모델 호출 안 함

→

② 모델 판단
근거를 보고 insufficient

→

③ 정해 둔 안내 문구
“ 모른다 .” 대신 문의처 안내

실제 : T-10 · T-11 모두 ②에서 insufficient (상태 16/16 일치). 기준을 0.45 로 올리면 T-05(근거 있음) 를 잘못 버리고 T-11 은 여전히 통과 → 8/11 그대로

05-6 검증 설계의 반성 — 규칙 과적합과 보완 계획

INSIGHT **Hit@1 0.933 은 규칙 단어를 평가 질문을 보며 고른 덕일 수 있음 — 규칙별 기여와 hold-out 으로 재확인 필요**

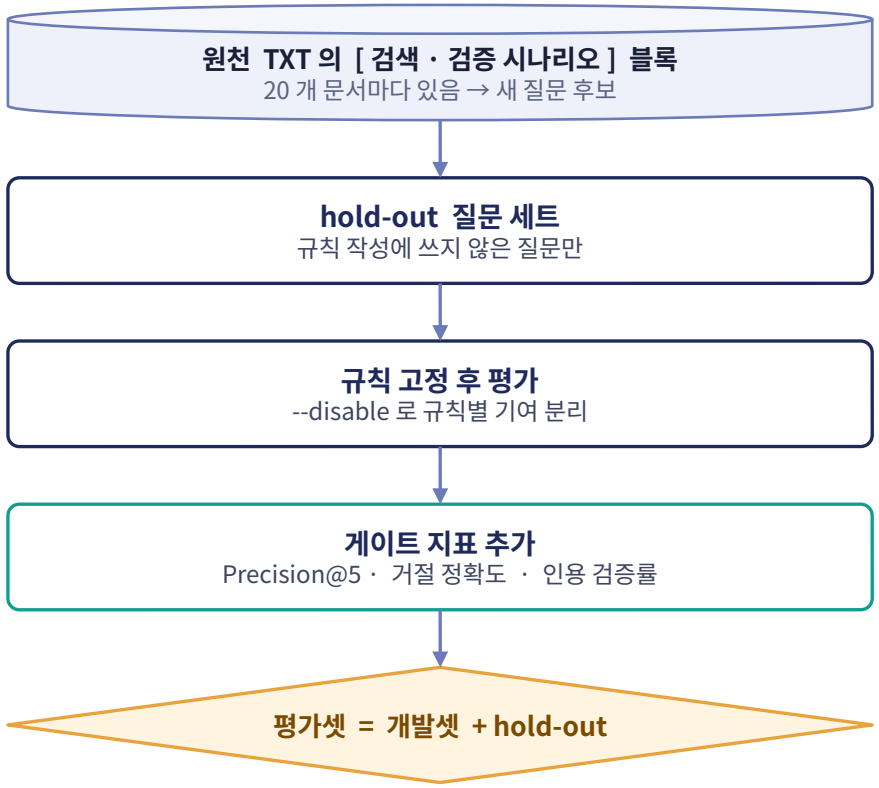
규칙	패턴 (정규식)	동작	근거 문장 요지
9 월 주문 → v1	9 월 |2026-09	pin EXC-007 · POL-VER-001	2026-09 주문은 v1
시행 전 정책	시행 예정 | 초안 |11 월 15 일	pin POL-VER-001	시행 전 초안은 적용 안 함
날짜가 있는 질문	\d+ 월 |\d+ 일	add POL-VER-001	주문일로 정책 버전 선택
내부 · 개인 정보	내부 | 회원 ID|CUS-| 상세 정보 | 주문 이력	pin + flag restricted	공개 답변엔 public 만

출처 : design/m5_routing.json · 근거 문서 POL-VER-001 ' 업무 규정'

위험 신호

- '11 월 15 일' 처럼 특정 평가 질문의 표현이 패턴에 들어감
- 규칙 대상 유형 (temporal · privacy) 에서만 auto 가 크게 앞섬
- 정밀도 0.33 — 맞힌 만큼 덜 맞는 정책도 함께 올라옴

보완 설계



05-7 설계 결정 기록 — 무엇을 버리고 무엇을 골랐나

INSIGHT 규모 (정책 19 · 조각 196 · 관계 118) 에 맞춰 단순한 쪽을 고르고 , 각 선택을 측정값이나 실패 사례로 정당화

결정	대안	선택	근거
청킹 단위	글자 300 · 겹침 50	**## 소제목 단위**	문장 끊김 0/116 vs 65/91 · 근거 위치가 곧 소제목
구현 방식	LangChain	**OpenAI API 직접 호출**	단계별 입출력 확인 · raw 캐시 · 평가와 직접 연결
벡터 인덱스	IVF · HNSW	**Flat(IP) + IDMap2**	196 조각은 정확 검색으로 충분 · HNSW 는 삭제 불가
그래프 저장	Neo4j	**NetworkX + JSON**	노드 80 · 관계 118 · 파일로 버전 관리 · 서버 불필요
순위 결합	점수 가중합	**RRF (k=60)**	척도가 다른 두 점수를 순위로 결합 · 가중치 튜닝 불필요
그래프 사용 조건	항상 결합	**출발 개념 ≥ 2 일 때**	개념 1 개면 그래프 순위가 잡음 (negative 유형 역효과)
라우팅	LLM 분류기	**정규식 규칙 4 개**	근거 문서 문장으로 설명 가능 · 지연 0 · 끄고 켜며 측정
권한 처리	검색 시 필터	**인덱싱 전 제외 + 플래그**	필터 누락 한 번이 곧 노출 → 저장 단계에서 차단

05-8 배운 점 — 다음 프로젝트에 가져갈 것

INSIGHT 성능을 바꾼 것은 모델 교체가 아니라 데이터 이해 · 단위 · 검사 · 게이트 — 네 가지 모두 “측정하고 나서 결정”

01 데이터를 먼저 읽는다

진단 → 설계

링크 0 · 이름 참조 7 · 표기 변형을 먼저 발견했기 때문에 그래프와 별칭표가 “필요한 이유”를 갖게 됨

02 단위가 성능을 정한다

9 → 15/17

청킹 단위 (끊김 0/116) 와 순위 단위 (9 → 15/17) 변경이 어떤 파라미터 조정보다 효과가 컸음

03 LLM 출력은 검사 대상

28 → 118

게이트 4 개와 rejected 집계가 없었다면 v0.2 의 28 건 하락을 원인 없이 지나쳤을 것

04 평가는 사람이 아니라 게이트가

Hit@1 ▼ 차단

Recall 만 보면 ‘9 월’ 규칙 제거를 놓침 → 기준선 비교와 exit 1 로 회귀를 자동 차단

05-9 한계와 다음 단계

INSIGHT 그래프 성능의 상한은 도구가 아니라 온톨로지 스키마 — 다음 투자는 추출 · 스키마와 hold-out 평가

한계	근거	다음 단계
평가 과대 가능	규칙 단어를 평가 질문에서 선택	**hold-out 질문 세트 · 규칙별 기여 측정**
온톨로지 빈칸	배송지연 · 정책 버전 · 주문일 노드 없음 (Q-030 1/4)	**원인 관계 · 버전 타입 추가 , policy_history 연결**
미사용 원천	orders · catalog 엔터티 미연결	**권한 분리한 엔터티 그래프 (주문일 → 버전 자동 판정)**
정밀도 0.33	top5 중 2/3 비정답	**cross-encoder 재순위 · 근거 선별**
근거 없음 판정	점수 하나로 안 갈림 (0.467 vs 0.448)	**점수 기준 + 모델 insufficient + 안내 문구**
답변 평가 범위	16 문항 15/16 · 인용 변형 1 건	**인용 복사 지시 · 평가 30 개 전체로 확대**

05-10 로드맵 — 검증 강화 → 지식 확장 → 현장 연결

INSIGHT 다음 투자 순서는 "믿을 수 있게 → 더 알게 → 현장에 붙게" — 단계마다 확인할 지표를 먼저 정함

1 단계 · 검증 강화

- hold-out 질문 세트 · 규칙별 기여 측정
- 근거 없음 · 거절 안내 문구 고정
- 답변 평가를 평가 질문 30 개로 확대

확인 지표
Precision@5 · 거절 정확도 · 인용 검증률

2 단계 · 지식 확장

- 온톨로지에 배송지연 · 정책 버전 · 주문일 노드
- policy_history 연결 → 버전 규칙을 그래프로
- cross-encoder 재순위로 정밀도 개선

확인 지표
temporal · multi_hop Recall · Q-030

3 단계 · 현장 연결

- 상담 콘솔에 JSON API 연동
- 권한 분리된 orders · catalog 엔터티 연결
- 상담 로그로 질문 세트 · 동의어 갱신

확인 지표
응답 시간 · 재문의율 · 보류 시간

데이터를 먼저 읽고 ,
측정으로 결정하고 , 근거로 설명한다

원천 데이터 진단 → 설계 결정 → 실험 → 평가 게이트까지 모든 단계를 숫자와 원문으로 추적 가능하게 만든 Hybrid RAG

데이터 진단

링크 0 · 이름 참조 7 · 표기 변형 → 온톨로지 설계

측정 기반 결정

청킹 0/116 · 스키마 28→118 · 순위 9→15/17

품질 게이트

내용 해시 캐시 · 버전 배포 · exit 1

PART

06

사용 가이드

결과 자료 · 실행 · 최종 코드 · 확장

06-1 결과 자료 구성

06-2 실행 방법

06-3 파이썬에서 부르기

06-4 명령과 점검 순서

06-5 확장하기

06-1 결과 자료 구성 — 무엇을 어디에 쓰나

INSIGHT 목적마다 여는 파일이 다름 — 시연은 앱 , 설명은 설명서 , 숫자는 CSV, 재현 · 교육은 모듈 패키지

```
a5-result/
├ run_app.bat · app_rag.py    웹 화면
├ A5_RAG_ 화면과 _ 모델설명 .html   설명서
├ m5_retriever.py · rag_answer.py
│                            검색기 · 답변 · 검증
├ m5_search.py · m5_18_compare.py
├ m6_19 · m6_20 · m6_21_*.py   검증 · 테스트
├ m1lib ~ m6lib.py            공통 코드
├ dataset/   faq · policies · md 19
├ design/     스키마 · 동의어 · 규칙
│            기준선 · 테스트 질문
├ outputs_m2/ ontology.json · raw/( 답 24)
├ outputs_m4/ 임베딩 · 캐시
├ outputs_m5/ eval_report.csv
├ reference/ 평가 질문 30
└ .env.example · requirements.txt
```

목적	여는 것	보이는 것
시연 (상담 화면)	run_app.bat → 브라우저	질문 → 정책 · 근거 문장 · 관계 경로 · 답변 · 검증
모델 설명	A5_RAG_ 화면과 _ 모델설명 .html	화면별 의미 · 설계 근거 · 성능 · 한계 · 예상 질문
숫자 확인	outputs_m5/eval_report.csv · m6_21 실행 → outputs_m6/	30 개 질문 × 4 방법 · 답변 16 개 검사 결과
검색만 붙이기	m5_search.py --json · m5_retriever.py	다른 시스템에 넘길 근거 패키지 JSON
재현 · 교육	m1.zip ~ m6.zip · 모듈별 교안	단계별 실습과 실제 출력
포트폴리오	이 문서 (pptx · pdf)	배경 · 데이터 · 프로세스 · 결과 · 회고

데이터는 교육용 합성 데이터 · .env(키) 는 어느 묶음에도 들어 있지 않음

06-2 실행 방법 — 키 없이 되는 것과 키가 필요한 것

INSIGHT 임베딩 · 답변을 파일로 저장해 두어 평가 질문 30 개와 검증 스크립트는 API 키 없이 그대로 재현

1 압축 풀기

a5-result.zip → 원하는 폴더 (예 : C:\rag\a5-result)

2 실행

run_app.bat 더블클릭 — 패키지 설치 후 브라우저 http://localhost:8501
또는 pip install -r requirements.txt
streamlit run app_rag.py

3 키 (선택)

.env.example → .env 로 복사 후 OPENAI_API_KEY 입력
키는 공유 · 압축 · 화면에 넣지 않음

기능	키 없이	키 필요
평가 질문 30 개 검색 · 그래프 · 평가 탭	○	
직접 입력한 새 질문 검색		○ (질문 임베딩 1 회 , 이후 캐시)
답변 만들기 — 저장된 답이 있는 질문	○	
답변 만들기 — 새 질문 · 새 근거		○ (gpt-4o-mini)
m5_18_compare · m6_19 · m6_20 · m6_21	○	

증상	대처
No module named faiss	pip install faiss-cpu
포트 8501 사용 중	streamlit run app_rag.py --server.port 8502
직접 입력 시 키 안내	.env 의 키 이름 OPENAI_API_KEY 확인
그래프가 빈 화면	다른 브라우저 · 새로고침 (PyVis in_line)
한글 깨짐 (Windows)	run_app.bat 사용 (UTF-8 설정 포함)

06-3 최종 코드 사용법 ① 파이썬에서 부르기

INSIGHT 검색 → 근거 → 답변 → 검증이 함수 네 개 — 화면 (app_rag.py) 도 같은 함수를 부를 뿐

```
from m5lib import question_vectors
from m5_retriever import Retriever
from rag_answer import answer, rule_sections, verify

q = "9 월  25 일 주문의 카드 환불은 승인 후 몇 영업일인가요 ?"

# 1) 질문 임베딩 ( 새 질문만 API 1 회 , 이후 캐시 )
qv, _ = question_vectors([{"question": q}], apply=True)

# 2) 검색 — 근거 패키지 (dict)
res = Retriever("auto", k=5).search(q, qv[0])

# 3) 답변 — 규칙 정책의 업무 규정 조각 포함
rec, ctx, prompt = answer(q, res, extra_ctx=rule_sections(res))
a = rec["data"]      # answer · status · citations

# 4) 검증 — 인용 · 원문 · 숫자 ( 질문 숫자 제외 )
v = verify(a, ctx, question=q)
print(a["status"], a["answer"], v["ok"])
```

값	내용
res["route"] · rules_fired · flags	어떤 경로 · 규칙 · restricted 여부
res["results"][i]	doc_id · title · sources · rules · evidence(2) · path
res["graph_missing"]	그래프에 없는 질문 개념 → 상담원 경고
a["status"]	answered · conditional · insufficient · refused
a["citations"]	chunk_id + 원문에서 옮긴 quote
v["ok"]	인용 근거 안 · 원문 일치 · 숫자 근거에 — 모두 통과

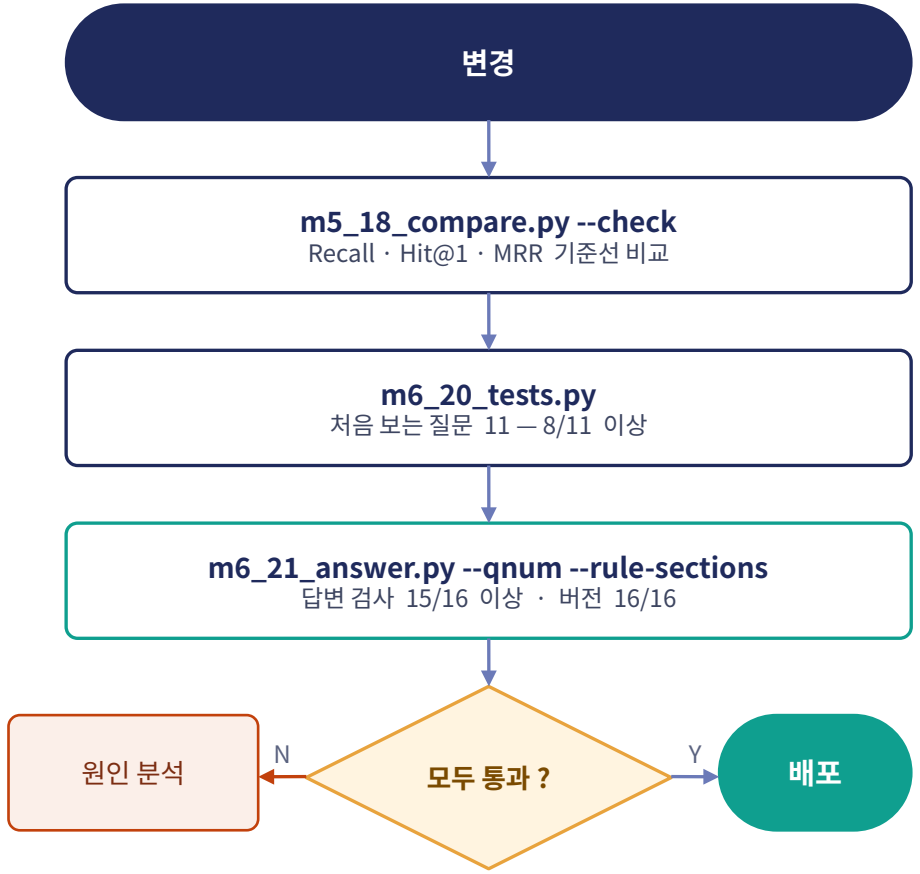
Retriever(method="auto" | "hybrid" | "vector" | "graph", k=5, disabled=[" 규칙 이름 "])

status 가 insufficient · refused 면 모델 답 대신 정해 둔 안내 문구를 내보냄

06-4 최종 코드 사용법 ② 명령과 변경 후 점검 순서

INSIGHT 무엇을 바꾸든 같은 순서로 다시 잰다 — 검색 회귀 → 처음 보는 질문 → 답변 검사 , 하나라도 나빠지면 멈춤

명령	하는 일
python m5_search.py --id Q-001 [--method vector] [--json]	질문 하나 검색 · 근거 패키지 · 로그
python m5_search.py " 새 질문 "	새 질문 검색 (질문 임베딩 · API)
python m5_18_compare.py [--by-type] [--wins]	30 개 × 4 방법 평가 · eval_report.csv
python m5_18_compare.py --check [--disable " 규칙 "]	기준선 대비 하락 시 exit 1
python m6_19_verify.py	근거 원문 대조 · 검증기 시험
python m6_20_tests.py [--embed] [--detail T-03]	테스트 질문 11 검색 점검
python m6_21_answer.py --qnum --rule-sections [--only Q-005 --show]	답변 16 · 상태 · 인용 · 말 · 버전 검사



기준선 저장 : m5_18_compare.py --save-baseline (의도한 개선 뒤에만)

06-5 확장하기 — 문서 · 규칙 · 테스트 · 모델을 바꿀 때

INSIGHT **바꾸는 곳은 대부분 설정 파일 (design/) — 코드보다 데이터 · 설계를 고치고 , 매번 앞 장의 순서로 다시 잰다**

1 새 정책 문서 추가

1. dataset/md/ 에 문서 · policies.csv 에 한 줄
2. 임베딩 다시 : m4lib.build_embeddings(refresh=True) (API · 전체 재임베딩 , 소량)
3. 온톨로지 : m2 패키지에서 추출 → m2_08_save → ontology.json 교체
4. 평가 · 테스트 질문에 그 문서용 질문 추가

2 라우팅 규칙 추가

1. design/m5_routing.json 에 name · regex · pin/add · why
2. 근거가 되는 정책 문장을 why 에 적기
3. m5_18_compare --check 로 다른 질문 영향 확인
4. --disable 로 그 규칙의 기여 측정

3 테스트 질문 추가

1. design/m6_tests.json 에 question · expect_docs · expect_status
2. 필요하면 first · not_first · flag · must_say · no_evidence
3. m6_20_tests.py --embed (새 질문 임베딩 · API)
4. m6_21_answer.py 로 답변까지 확인

4 모델 교체

1. .env 의 OPENAI_EMBED_MODEL · OPENAI_MODEL
2. 임베딩 모델을 바꾸면 조각 · 질문 전부 다시 (캐시 열쇠에 모델 포함)
3. 답변 모델을 바꾸면 m6_21 --refresh 로 다시 답하고 검사
4. 바꾸기 전후를 같은 질문으로 비교

부록 · 이 PPT 를 만들기 위해 입력한 프롬프트

INSIGHT 한 번에 완성하지 않음 — 프롬프트 13 개로 "내용 → 구조 → 근거 → 맥락 → 사용법" 순서로 다듬어 v1 → v9

1. 자 . M5 를 프로젝트 발표자료라고 생각하고 html 로 발표자료 만들어줄래 . 목업 및 화면 캡처 풍부하게 . 발표멘트는 별도로 — HTML
2. 기술자 포트폴리오쓸 자료로 만들어줘 . Ppt 가 편하면 ppt 러 — v1
3. 상단에 인사이트 넣어줄래 . 그리고 좀더 기술적으로 빡빡하게 , 프로세스도 그리고 — v2
4. 너무 별로인데 . 원데이터에 대한 내용도 잘 없고 . 프로세스도 너무 단순하게 그리고 . — v3
5. 제목을 실제 포폴처럼 번호를 붙이든지 . 파트를 나누던지 할래 ? — v4
6. 그리고 맨 앞장에 이걸 개발하게 된 이유등을 넣어야 하지 않을까 ? 그리고 04 번은 좀더 뭔가를 해야할듯하고 프로세스 다이어그램은 좋음 . 그런데 나온 결과에 대한 화면 설명등도 여기에 넣는걸로 하자 . 페이지수 많아도 됨 . 영상물 없다는 전제하에 — v5
7. 그리고 이걸 개발하게 되면 콜센터 직원은 어떻게 한다는 가상시나리오를 먼저 보여주던지 . 목업으로 — v5
8. 그리고 지금 우리 rag 그래프는 그래프 rag 인거 맞지 ? — 확인
9. 이런 내용도 간단하게 포폴에 넣어야 하는거 아닌가 ? — v6
10. pdf 로 줄래 — PDF
11. 그리고 a5 에 사용기술도 넣어야 하지 않니 ? 왜 랭체인 안하고 gptAPI 했는지 , 왜 그래프도 네트워크 그래프로 그렸는지등 . 한장 간단히 앞에 요약해야 하지 않을까 ? — v7
12. 맨 마지막장에 참고로 내가 이 ppt 를 만들위해서 넣은 프롬프트만 모아서 줘 — 이 장
13. 그럼 이제 result 의 내용에도 어떤 이슈가 있었는지를 넣어야 겠지 ? 그리고 result 자료 사용법에 대한것도 넣어줘 . 최종코드사용법도 (pptx 로 만든자료를 뜻함) — v9